


FRONT PAGE

Nombre Alumno / DNI	Alejandro García Casado – 49158343Y
Título del Programa	2º PHE Cybersecurity
N.º Unidad y Título	UNIT 16 - Computing Research Project
Año académico	2025-2026
Profesor de la unidad	Amalio
Título del Assignment	AB 1
Día de emisión	02/10/2025
Día de entrega	21/10/2025
Declaración del estudiante	Certifico que la presentación del assignment es completamente mi propio trabajo y entiendo completamente las consecuencias del plagio. Entiendo que hacer una declaración falsa es una forma de mala práctica. Fecha: 21/10/2025 Firma del alumno: 

Plagio

El plagio es una forma particular de hacer trampa. El plagio debe evitarse a toda costa y los alumnos que infrinjan las reglas, aunque sea inocentemente, pueden ser sancionados. Es su responsabilidad asegurarse de comprender las prácticas de referencia correctas. Como alumno de nivel universitario, se espera que utilice las referencias adecuadas en todo momento y mantenga notas cuidadosamente detalladas de todas sus fuentes de materiales para el material que ha utilizado en su trabajo, incluido cualquier material descargado de Internet. Consulte al profesor de la unidad correspondiente o al tutor del curso si necesita más consejos.

Tabla de contenido

1. Introducción 3

 1.1 Contextualización del auge de la IA generativa..... 3

 1.2 Relevancia del tema en ciberseguridad 3

 1.3 Problema central y justificación 4

 1.4 Objetivos generales y específicos 4

 1.5 Pregunta de investigación 5

 1.6 Limitaciones del estudio 5

2. Revisión de la literatura 6

 2.1 Qué es la IA generativa y cómo funciona 6

 2.2 Casos recientes de su uso en ciberataques 6

 2.2.1 Deepfakes 6

 2.2.2 Phishing automatizado..... 7

 2.2.3 Malware asistido por IA 7

 2.2.4 Suplantación de identidad y redes sociales..... 7

 2.3 Impacto de la IA generativa en ciberseguridad 8

 2.4 Comparación con amenazas tradicionales 8

 2.5 Lagunas de investigación 9

 2.6 Perspectiva futura 9

3. Metodología planteada..... 10

 3.1 Enfoque teórico-descriptivo (análisis documental) 10

 3.2 Fuentes..... 11

 3.3 Métodos de análisis..... 11

 3.3.1 Revisión comparativa 12

 3.3.2 Análisis de tendencias 12

 3.3.3 Clasificación de amenazas 13

 3.3.4 Identificación de riesgos emergentes 13

 3.4 Criterios de selección de fuentes 14

 3.5 Limitaciones del método 14

 3.6 Cierre de la primera parte 15

Bibliografía 15

1. Introducción

1.1 Contextualización del auge de la IA generativa

La inteligencia artificial generativa se ha hecho bastante conocida en los últimos años. Modelos como ChatGPT, DALL·E o Gemini pueden generar texto, imágenes, audio o incluso código a partir de simples instrucciones. Lo impresionante es que cualquiera puede acceder a estas herramientas mediante aplicaciones o APIs, sin necesidad de ser experto en programación.

Estas tecnologías no solo son populares, sino también muy potentes. Pueden imitar estilos de escritura, crear imágenes realistas o resumir información de manera sorprendente. Y sí, eso está bien para tareas creativas o productividad. Pero, como veremos, esa misma capacidad se puede usar para cosas malas. Por ejemplo, generar deepfakes, redactar correos de phishing o incluso crear fragmentos de código malicioso.

1.2 Relevancia del tema en ciberseguridad

Sabemos que, en ciberseguridad, la IA generativa cambia bastante las reglas del juego. Antes, los atacantes necesitaban habilidades técnicas o bastante tiempo para preparar un ataque convincente. Ahora, con estos modelos, pueden automatizar tareas y hacer ataques más realistas.

Informes recientes de Europol y Kaspersky indican que los ataques que usan IA generativa están creciendo y son más difíciles de detectar. Los sistemas de defensa tradicionales, como filtros de correo o antivirus, no siempre pueden seguir el ritmo. Así que sí, entender cómo se usa la IA generativa en ataques es importante, porque no es solo un riesgo futuro: ya está ocurriendo.

1.3 Problema central y justificación

El problema principal es entender cómo se usa la IA generativa para atacar y qué riesgos representa hoy y mañana. Honestamente, la literatura aún tiene huecos: hay muchos estudios sobre cómo la IA ayuda a defender, pero pocos que analicen su uso ofensivo.

La justificación es simple: la IA generativa es cada vez más accesible, los ataques se vuelven más sofisticados y las regulaciones no avanzan al mismo ritmo. Si no estudiamos esto ahora, las empresas y usuarios podrían quedarse atrás, sin defensas adecuadas. Además, anticipar posibles futuros ataques ayuda a diseñar estrategias de prevención más sólidas.

1.4 Objetivos generales y específicos

Objetivo general:

Analizar cómo la IA generativa se usa como herramienta para ciberataques y qué implicaciones tiene para la seguridad digital.

Objetivos específicos:

- Explicar de forma clara las capacidades de los modelos de IA generativa que son relevantes para la seguridad.
- Revisar casos actuales de ataques usando IA: deepfakes, phishing automatizado, generación de malware y manipulación de información.
- Evaluar qué tan efectivas son las defensas actuales frente a estos ataques.
- Explorar escenarios futuros y proponer ideas generales de mitigación.

1.5 Pregunta de investigación

¿Cómo están usando los atacantes la IA generativa para crear nuevas formas de ciberataques y qué impacto podrían tener estas amenazas en la ciberseguridad en el futuro?

Esta pregunta guía todo el proyecto. Cada análisis, caso o conclusión que incluimos se relaciona con ella.

1.6 Limitaciones del estudio

Este trabajo se basa en revisión documental y análisis teórico, así que no haremos experimentos reales ni generaremos ataques con IA. Eso sería poco ético y arriesgado.

Otra limitación es la rapidez con la que cambian los modelos y técnicas de IA. Algunos estudios o datos recientes pueden quedar desactualizados en meses. Por eso, priorizamos referencias de los últimos dos o tres años y fuentes confiables.

Finalmente, aunque tocaremos aspectos legales y éticos, el enfoque principal es técnico y estratégico, tratando de mostrar qué está pasando y qué podría pasar, sin desviarnos demasiado en la teoría legal.

2. Revisión de la literatura

2.1 Qué es la IA generativa y cómo funciona

La IA generativa es un tipo de inteligencia artificial que puede crear contenido nuevo: texto, imágenes, audio o incluso código. Básicamente funciona aprendiendo patrones a partir de muchísimos datos. Por ejemplo, ChatGPT genera textos, DALL·E crea imágenes según lo que describas y Gemini mezcla texto e imagen.

La IA no “entiende” realmente lo que hace, solo sigue los patrones que ha aprendido. Por eso, a veces genera cosas raras o equivocadas. Pero esa misma capacidad para imitar y crear hace que sea un riesgo para la ciberseguridad. Alguien sin mucha experiencia técnica puede generar un correo de phishing convincente o un deepfake que engañe a otras personas. Honestamente, eso cambia mucho el panorama comparado con hace solo unos años.

2.2 Casos recientes de su uso en ciberataques

2.2.1 Deepfakes

Los deepfakes son contenidos falsos, vídeos o audios, que imitan personas reales. Se usan para engañar o extorsionar. Por ejemplo, hubo un caso en Reino Unido donde la voz de un director fue clonada para autorizar una transferencia bancaria. Suena un poco aterrador, ¿no? Lo que antes requería mucho tiempo y habilidades, ahora cualquiera con la herramienta adecuada puede intentarlo.

Además, los deepfakes no solo afectan a empresas; también pueden manipular la opinión pública o redes sociales. Por eso es importante entender cómo funcionan y qué medidas se pueden tomar, aunque todavía no hay soluciones 100% eficaces.

2.2.2 Phishing automatizado

Antes, un correo de phishing era fácil de detectar: frases raras, faltas de ortografía, errores de formato. Ahora la IA generativa puede escribir correos muy convincentes. Puede imitar a un compañero de trabajo, a un jefe o incluso a una empresa conocida. Esto hace que los ataques sean más efectivos y rápidos.

Por ejemplo, se han detectado campañas donde se generaban cientos de correos únicos en minutos, cada uno adaptado al receptor. Antes, solo un hacker con experiencia podía hacer algo así en unas horas o días. Esto también aumenta el riesgo de que más personas caigan en el engaño, porque el mensaje parece real.

2.2.3 Malware asistido por IA

Algunos investigadores han probado que la IA generativa puede ayudar a crear malware básico o scripts de ataque solo a partir de instrucciones de texto. Esto no significa que sea fácil crear ataques complejos, pero sí baja la barrera para generar malware. Y claro, eso significa que personas sin experiencia pueden montar algo peligroso.

Este tipo de malware puede adaptarse más rápido, cambiar su comportamiento y evadir detecciones tradicionales. No es perfecto todavía, pero sí es preocupante. Y sí, hace que los equipos de seguridad tengan que estar más atentos que antes.

2.2.4 Suplantación de identidad y redes sociales

La IA generativa también se usa para crear identidades falsas en redes sociales. Puede generar fotos, perfiles completos y hasta publicaciones coherentes. Esto se ha visto en campañas de desinformación o fraudes online.

Un ejemplo reciente: un ataque donde se crearon varios perfiles falsos en LinkedIn para enviar mensajes de phishing a empleados de empresas de tecnología. Los mensajes parecían totalmente legítimos. Incluso los sistemas automáticos tienen problemas para detectar esto.

2.3 Impacto de la IA generativa en ciberseguridad

La IA generativa cambia las reglas del juego:

- Permite ataques más rápidos y masivos. Lo que antes tardaba días, ahora se hace en minutos.
- Las defensas tradicionales ya no bastan. Antes se detectaban ataques por patrones conocidos, ahora los atacantes los cambian constantemente.
- Aumenta la presión sobre los profesionales de ciberseguridad. No solo hay más ataques, también son más sofisticados.

Aun así, no todo es malo. Estos cambios también obligan a mejorar estrategias, implementar sistemas de detección por comportamiento y capacitar mejor a los equipos.

2.4 Comparación con amenazas tradicionales

Antes, los ataques eran más previsibles. Dependían de la intervención humana y se repetían patrones claros. Ahora, la IA permite automatizar y personalizar ataques. Esto significa que:

- Más personas pueden ejecutar ataques sin ser expertos.
- Los ataques cambian constantemente, dificultando su detección.
- Se necesita invertir en nuevas tecnologías de defensa y formación del personal.

En otras palabras, los ataques tradicionales eran como balas, los de IA generativa son flechas que cambian de dirección mientras vuelan. Sí, suena dramático, pero es una buena analogía.

2.5 Lagunas de investigación

A pesar de todo lo que se ha escrito, hay huecos importantes:

- Pocos estudios analizan cómo los atacantes combinan varias técnicas de IA generativa.
- Falta información sobre eficacia de contramedidas frente a ataques adaptativos.
- No hay muchos estudios sobre impacto en infraestructuras críticas, como energía o transporte.

Eso significa que todavía hay mucho que investigar. Y sí, esto es una oportunidad para aprender y proponer soluciones.

2.6 Perspectiva futura

Todos sabemos que la IA generativa va a seguir avanzando. Esto podría:

- Generar ataques más complejos y difíciles de detectar.
- Crear deepfakes más convincentes, que sean imposibles de distinguir de la realidad.
- Automatizar la suplantación de identidad a gran escala.

De igual manera, también habrá herramientas defensivas que usen IA. La diferencia es que la carrera entre atacantes y defensores será más rápida y más difícil de controlar. Por eso, entender estos riesgos ahora es clave.

3. Metodología planteada

3.1 Enfoque teórico-descriptivo (análisis documental)

Para este proyecto, el enfoque elegido es teórico-descriptivo, basado en análisis documental. Es decir, no vamos a hacer experimentos prácticos ni encuestas, sino que vamos a examinar información existente, compararla y extraer conclusiones sobre cómo la IA generativa está afectando la ciberseguridad.

La idea es entender patrones, impactos y tendencias sin necesidad de probar ataques nosotros mismos, porque eso sería ilegal y peligroso. Se deben mirar estudios, informes, casos reales y artículos académicos para ver qué está pasando y qué riesgos emergen. Honestamente, es más seguro y también más interesante, porque permite ver muchos casos diferentes y sacar conclusiones más generales.

El análisis documental permite, además, identificar lagunas de conocimiento, que son esos puntos donde la información aún es escasa. Y sí, en este tema hay varias, sobre todo en ataques automatizados o en infraestructuras críticas. También ayuda a organizar la información y a tener una base sólida para después proponer recomendaciones o alertas que podrían ser útiles para equipos de ciberseguridad o investigadores futuros.

3.2 Fuentes

Las fuentes que vamos a usar son variadas, para tener un panorama más completo:

- Artículos académicos: Publicaciones revisadas por expertos sobre IA generativa, deepfakes y ciberseguridad. Esto nos da un soporte sólido y confiable.
- Informes de ciberseguridad: Por ejemplo, los de Europol, Kaspersky o Cisco. Son útiles porque incluyen datos recientes y análisis de tendencias, algo que los papers académicos no siempre reflejan.
- Estudios de caso: Casos concretos de ataques, fraudes o brechas de seguridad donde se haya identificado el uso de IA generativa. Esto ayuda a ver cómo los conceptos se aplican en la vida real, y además da ejemplos concretos para ilustrar los riesgos.

La mejor opción es usar una combinación de estas fuentes para contrastarlas entre sí, y no depender solo de un tipo de documento. Así se evita sesgo y se obtiene un análisis más completo. Además, tener distintos tipos de fuentes permite cubrir desde lo técnico hasta lo práctico, que es justo lo que necesitamos para entender un fenómeno tan amplio como la IA generativa en ciberseguridad.

3.3 Métodos de análisis

El análisis documental no se limita a leer y resumir información. El tema es un poco más organizada. Vamos a aplicar varias técnicas complementarias para entender mejor cómo la IA generativa impacta en ciberseguridad.

3.3.1 Revisión comparativa

Primero, haremos una revisión comparativa. Esto significa que vamos a comparar información entre distintos tipos de fuentes. Por ejemplo, un informe de Europol puede dar datos sobre la cantidad de ataques de phishing automatizados, mientras un artículo académico explica cómo funciona técnicamente la generación de estos ataques. Al contrastar ambos puntos de vista, podemos ver coincidencias, diferencias y lagunas, y eso nos ayuda a interpretar mejor los riesgos reales.

Además, la revisión comparativa permite identificar tendencias a lo largo del tiempo. Por ejemplo, podemos analizar cómo han evolucionado los deepfakes en los últimos tres años: desde vídeos básicos que se veían falsos, hasta audios clonados de ejecutivos que pueden engañar a bancos y empresas. Esto nos da un panorama más completo y actualizado, que es justo lo que necesitamos.

3.3.2 Análisis de tendencias

Otra técnica que vamos a usar es el análisis de tendencias. Esto implica observar patrones en los ataques y evaluar su evolución. Por ejemplo, la frecuencia de correos de phishing generados por IA ha aumentado significativamente desde 2022. Es importante saber que también podemos detectar tendencias emergentes, como la combinación de deepfakes con ingeniería social, o ataques automatizados a cuentas corporativas en redes sociales.

Este análisis no solo nos permite ver lo que ya está pasando, sino que también ayuda a predecir riesgos futuros. No es que podamos decir con certeza qué pasará, pero sí podemos estimar qué tipos de ataques podrían volverse más frecuentes y cuáles podrían ser los más dañinos. Por ejemplo, ataques combinados que incluyan malware generado por IA más deepfakes para manipular empleados de empresas grandes.

3.3.3 Clasificación de amenazas

Además, vamos a clasificar los ataques según tres criterios: impacto, facilidad de ejecución y potencial de propagación. Esto permite organizar la información de manera más clara. Por ejemplo:

- Un correo de phishing sencillo, aunque sea automatizado, tiene bajo impacto individual, pero puede propagarse rápido.
- Un deepfake que permite fraude financiero tiene alto impacto, pero es más complejo de generar.
- Malware asistido por IA puede ser relativamente fácil de crear para un atacante con conocimientos básicos, pero su propagación depende de otros factores.

La clasificación ayuda a priorizar qué amenazas requieren más atención y recursos, algo muy útil para los equipos de ciberseguridad.

3.3.4 Identificación de riesgos emergentes

Un aspecto que considero muy importante es identificar riesgos emergentes. Por ejemplo, la IA generativa podría usarse en el futuro para atacar infraestructuras críticas, como redes eléctricas, sistemas de transporte o bancos. Aunque no haya muchos casos reportados, es probable que la tendencia siga en aumento.

Otro riesgo emergente es la automatización de ataques combinados. Por ejemplo, un atacante podría usar IA para generar correos de phishing, deepfakes y malware de manera simultánea. Eso aumentaría la eficacia del ataque y reduciría el tiempo necesario para ejecutarlo.

La idea es que, al identificar estos riesgos, podamos informar a profesionales y empresas sobre posibles escenarios antes de que ocurran, lo cual es más proactivo que solo reaccionar a incidentes después de que suceden.

3.4 Criterios de selección de fuentes

No todas las fuentes son igual de útiles. Por eso, establecemos algunos criterios de selección:

- Relevancia: Solo se incluyen fuentes que traten directamente sobre IA generativa y ciberseguridad. Por ejemplo, un estudio sobre deepfakes o malware asistido por IA.
- Actualidad: Prioridad a artículos y reportes de los últimos cinco años, porque este campo cambia muy rápido.
- Fiabilidad: Informes de organizaciones reconocidas (Europol, Kaspersky, Cisco) o artículos revisados por pares.
- Cobertura: Buscamos diversidad, que incluya análisis técnico, casos prácticos y estadísticas, para tener una visión completa.

Esto nos asegura que el análisis sea consistente y fiable, sin depender de información desactualizada o incompleta.

3.5 Limitaciones del método

Como todo estudio, este enfoque tiene limitaciones. No podemos probar ataques reales, así que no se puede medir la efectividad real de cada técnica en entornos controlados. También dependemos de la información disponible, que puede estar incompleta o sesgada. Por ejemplo, los informes a veces solo muestran ataques detectados, no los que no se reportaron.

Además, algunos riesgos futuros solo se pueden estimar, no confirmar. Esto significa que nuestras conclusiones sobre amenazas emergentes son más bien proyecciones, basadas en patrones observados y opiniones de expertos. Aun así, creo que sigue siendo útil para entender el panorama y preparar estrategias preventivas.

3.6 Cierre de la primera parte

En resumen, esta primera parte de la metodología establece las bases para todo el análisis del proyecto. Hemos definido que el enfoque será teórico-descriptivo, apoyado en análisis documental, y que las fuentes incluirán artículos académicos, informes de ciberseguridad y estudios de caso. También hemos explicado cómo se aplicarán técnicas como la revisión comparativa, el análisis de tendencias, la clasificación de amenazas y la identificación de riesgos emergentes.

Sabemos es que hasta aquí tenemos una estructura sólida, pero todavía quedan elementos por desarrollar. En la segunda parte abordaremos con más detalle los criterios de selección de fuentes, técnicas más específicas de análisis y limitaciones, además de una reflexión final sobre cómo todo esto nos ayudará a responder la pregunta de investigación.

De esta forma, dejamos claro qué se ha hecho y qué falta, asegurando que la metodología sea transparente y replicable, y al mismo tiempo manteniendo la continuidad del proyecto para completarlo de manera organizada en la siguiente sección.

Bibliografía

1. Auge de la IA generativa y relevancia en ciberseguridad
 - Fuente: OpenAI. (2023). ChatGPT: Language Models and AI Applications.
 - Información utilizada: Descripción general de ChatGPT y otros modelos generativos, páginas principales de la documentación online.
 - Link: <https://openai.com/research/chatgpt>
2. IA generativa, deepfakes y amenazas actuales
 - Fuente: Kaspersky. (2025). Ciberamenazas que imitan herramientas de IA como ChatGPT.
 - Información utilizada: Casos de uso de IA generativa en ataques, estadísticas recientes de ataques y tendencias observadas.
 - Link: <https://www.kaspersky.com/blog/ai-generated-cyberattacks>

3. Impacto de la IA en ciberseguridad y posibles riesgos futuros

- Fuente: Europol. (2024). Internet Organised Crime Threat Assessment (IOCTA 2024).
- Información utilizada: Secciones sobre ataques automatizados, deepfakes y riesgos emergentes; análisis de tendencias en cibercrimen.
- Link: <https://www.europol.europa.eu/publication-events/main-reports/internet-organised-crime-threat-assessment-iocta-2024>

4. Clasificación de amenazas y riesgos emergentes

- Fuente: Cisco. (2024). Annual Cybersecurity Report.
- Información utilizada: Capítulos sobre deepfakes, malware automatizado y tendencias en ataques de IA generativa.
- Link: <https://www.cisco.com/c/en/us/products/security/security-reports.html>

5. Estudios de caso y ejemplos prácticos de ataques con IA

- Fuente: MIT Technology Review. (2023). The rise of AI-generated cyber threats.
- Información utilizada: Casos de ataques recientes usando deepfakes y phishing automatizado.
- Link: <https://www.technologyreview.com/2023/06/12/1072580/ai-generated-cyber-threats/>