


FRONT PAGE

Nombre Alumno / DNI	Alejandro García Casado – 49158343Y
Título del Programa	2º PHE Cybersecurity
N.º Unidad y Título	UNIT 16 - Computing Research Project
Año académico	2025-2026
Profesor de la unidad	Amalio
Título del Assignment	AB 1
Día de emisión	02/10/2025
Día de entrega	21/10/2025
Declaración del estudiante	Certifico que la presentación del assignment es completamente mi propio trabajo y entiendo completamente las consecuencias del plagio. Entiendo que hacer una declaración falsa es una forma de mala práctica. Fecha: 21/10/2025 Firma del alumno: 

Plagio

El plagio es una forma particular de hacer trampa. El plagio debe evitarse a toda costa y los alumnos que infrinjan las reglas, aunque sea inocentemente, pueden ser sancionados. Es su responsabilidad asegurarse de comprender las prácticas de referencia correctas. Como alumno de nivel universitario, se espera que utilice las referencias adecuadas en todo momento y mantenga notas cuidadosamente detalladas de todas sus fuentes de materiales para el material que ha utilizado en su trabajo, incluido cualquier material descargado de Internet. Consulte al profesor de la unidad correspondiente o al tutor del curso si necesita más consejos.

Tabla de contenido

1. Introducción.....	2
1.1 Contextualización del auge de la IA generativa	2
1.2 Relevancia del tema en ciberseguridad	3
1.3 Problema central y justificación.....	3
1.4 Objetivos generales y específicos	4
1.5 Pregunta de investigación	4
1.6 Limitaciones del estudio.....	5
2. Revisión de la literatura	5
2.1 Qué es la IA generativa y cómo funciona.....	6
2.2 Casos recientes de su uso en ciberataques	6
2.2.1 Deepfakes.....	6
2.2.2 Phishing automatizado	6
2.2.3 Malware asistido por IA	7
2.2.4 Suplantación de identidad y redes sociales	7
2.3 Impacto de la IA generativa en ciberseguridad.....	8
2.4 Comparación con amenazas tradicionales.....	8
2.5 Lagunas de investigación	8
2.6 Perspectiva futura	9
3. Metodología planteada.....	9
3.1 Enfoque teórico-descriptivo (análisis documental)	9
3.2 Fuentes	10
3.3 Métodos de análisis.....	11
3.3.1 Revisión comparativa.....	11
3.3.2 Análisis de tendencias	11
3.3.3 Clasificación de amenazas	12
3.3.4 Identificación de riesgos emergentes	13
3.4 Criterios de selección de fuentes	13
3.5 Limitaciones del método	14
3.6 Justificación de la elección metodológica y descarte de alternativas	14
3.7 Cierre de la primera parte	15
4. Progreso del proyecto.....	16
5. Ajustes realizados al proyecto	17
6. Resultados Iniciales y Análisis de Casos	19
6.1. Ingeniería Social Automatizada: El salto de calidad y volumen en el Phishing	20

6.2. Fraude Financiero mediante Deepfakes de Audio y Video	21
6.3. Desarrollo de Malware y la reducción de barreras técnicas	21
7. Discusión: Interpretación de los hallazgos y contraste teórico	22
7.1. La paradoja de la "Democratización del Cibercrimen"	22
7.2. El fin de la concienciación tradicional	23
7.3. Velocidad vs. Precisión: La nueva carrera armamentística	23
7.4. Hacia un cambio de paradigma defensivo	24
8. Conclusiones Preliminares de la Fase Intermedia	24
9. Revisión del Progreso y Planificación Futura	25

1. Introducción

1.1 Contextualización del auge de la IA generativa

La inteligencia artificial generativa se ha hecho bastante conocida en los últimos años. Modelos como ChatGPT, DALL·E o Gemini pueden generar texto, imágenes, audio o incluso código a partir de simples instrucciones. Lo impresionante es que cualquiera puede acceder a estas herramientas mediante aplicaciones o APIs, sin necesidad de ser experto en programación.

Estas tecnologías no solo son populares, sino también muy potentes. Pueden imitar estilos de escritura, crear imágenes realistas o resumir información de manera sorprendente. Y sí, eso está bien para tareas creativas o productividad. Pero, como veremos, esa misma capacidad se puede usar para cosas malas. Por ejemplo, generar deepfakes, redactar correos de phishing o incluso crear fragmentos de código malicioso.

1.2 Relevancia del tema en ciberseguridad

Sabemos que, en ciberseguridad, la IA generativa cambia bastante las reglas del juego. Antes, los atacantes necesitaban habilidades técnicas o bastante tiempo para preparar un ataque convincente. Ahora, con estos modelos, pueden automatizar tareas y hacer ataques más realistas.

Informes recientes de Europol y Kaspersky indican que los ataques que usan IA generativa están creciendo y son más difíciles de detectar. Los sistemas de defensa tradicionales, como filtros de correo o antivirus, no siempre pueden seguir el ritmo. Así que sí, entender cómo se usa la IA generativa en ataques es importante, porque no es solo un riesgo futuro: ya está ocurriendo.

1.3 Problema central y justificación

El problema principal es entender cómo se usa la IA generativa para atacar y qué riesgos representa hoy y mañana. Honestamente, la literatura aún tiene huecos: hay muchos estudios sobre cómo la IA ayuda a defender, pero pocos que analicen su uso ofensivo.

La justificación es simple: la IA generativa es cada vez más accesible, los ataques se vuelven más sofisticados y las regulaciones no avanzan al mismo ritmo. Si no estudiamos esto ahora, las empresas y usuarios podrían quedarse atrás, sin defensas adecuadas. Además, anticipar posibles futuros ataques ayuda a diseñar estrategias de prevención más sólidas.

1.4 Objetivos generales y específicos

Objetivo general:

Analizar cómo la IA generativa se usa como herramienta para ciberataques y qué implicaciones tiene para la seguridad digital.

Objetivos específicos:

- Explicar de forma clara las capacidades de los modelos de IA generativa que son relevantes para la seguridad.
- Revisar casos actuales de ataques usando IA: deepfakes, phishing automatizado, generación de malware y manipulación de información.
- Evaluar qué tan efectivas son las defensas actuales frente a estos ataques.
- Explorar escenarios futuros y proponer ideas generales de mitigación.

1.5 Pregunta de investigación

¿Cómo están usando los atacantes la IA generativa para crear nuevas formas de ciberataques y qué impacto podrían tener estas amenazas en la ciberseguridad en el futuro?

Esta pregunta guía todo el proyecto. Cada análisis, caso o conclusión que incluimos se relaciona con ella.

1.6 Limitaciones del estudio

Este trabajo se basa en revisión documental y análisis teórico, así que no haremos experimentos reales ni generaremos ataques con IA. Eso sería poco ético y arriesgado.

Otra limitación es la rapidez con la que cambian los modelos y técnicas de IA. Algunos estudios o datos recientes pueden quedar desactualizados en meses. Por eso, priorizamos referencias de los últimos dos o tres años y fuentes confiables.

Finalmente, aunque tocaremos aspectos legales y éticos, el enfoque principal es técnico y estratégico, tratando de mostrar qué está pasando y qué podría pasar, sin desviarnos demasiado en la teoría legal.

2. Revisión de la literatura

2.1 Qué es la IA generativa y cómo funciona

La IA generativa es un tipo de inteligencia artificial que puede crear contenido nuevo: texto, imágenes, audio o incluso código. Básicamente funciona aprendiendo patrones a partir de muchísimos datos. Por ejemplo, ChatGPT genera textos, DALL·E crea imágenes según lo que describas y Gemini mezcla texto e imagen.

La IA no “entiende” realmente lo que hace, solo sigue los patrones que ha aprendido. Por eso, a veces genera cosas raras o equivocadas. Pero esa misma capacidad para imitar y crear hace que sea un riesgo para la ciberseguridad. Alguien sin mucha experiencia técnica puede generar un correo de phishing convincente o un deepfake que engañe a otras personas. Honestamente, eso cambia mucho el panorama comparado con hace solo unos años.

2.2 Casos recientes de su uso en ciberataques

2.2.1 Deepfakes

Los deepfakes son contenidos falsos, vídeos o audios, que imitan personas reales. Se usan para engañar o extorsionar. Por ejemplo, hubo un caso en Reino Unido donde la voz de un director fue clonada para autorizar una transferencia bancaria. Suena un poco aterrador, ¿no? Lo que antes requería mucho tiempo y habilidades, ahora cualquiera con la herramienta adecuada puede intentarlo.

Además, los deepfakes no solo afectan a empresas; también pueden manipular la opinión pública o redes sociales. Por eso es importante entender cómo funcionan y qué medidas se pueden tomar, aunque todavía no hay soluciones 100% eficaces.

2.2.2 Phishing automatizado

Antes, un correo de phishing era fácil de detectar: frases raras, faltas de ortografía, errores de formato. Ahora la IA generativa puede escribir correos muy convincentes. Puede imitar a un compañero de trabajo, a un jefe o incluso a una empresa conocida. Esto hace que los ataques sean más efectivos y rápidos.

Por ejemplo, se han detectado campañas donde se generaban cientos de correos únicos en minutos, cada uno adaptado al receptor. Antes, solo un hacker con experiencia podía hacer algo así en unas horas o días. Esto también aumenta el riesgo de que más personas caigan en el engaño, porque el mensaje parece real.

2.2.3 Malware asistido por IA

Algunos investigadores han probado que la IA generativa puede ayudar a crear malware básico o scripts de ataque solo a partir de instrucciones de texto. Esto no significa que sea fácil crear ataques complejos, pero sí baja la barrera para generar malware. Y claro, eso significa que personas sin experiencia pueden montar algo peligroso.

Este tipo de malware puede adaptarse más rápido, cambiar su comportamiento y evadir detecciones tradicionales. No es perfecto todavía, pero sí es preocupante. Y sí, hace que los equipos de seguridad tengan que estar más atentos que antes.

2.2.4 Suplantación de identidad y redes sociales

La IA generativa también se usa para crear identidades falsas en redes sociales. Puede generar fotos, perfiles completos y hasta publicaciones coherentes. Esto se ha visto en campañas de desinformación o fraudes online.

Un ejemplo reciente: un ataque donde se crearon varios perfiles falsos en LinkedIn para enviar mensajes de phishing a empleados de empresas de tecnología. Los mensajes parecían totalmente legítimos. Incluso los sistemas automáticos tienen problemas para detectar esto.

2.3 Impacto de la IA generativa en ciberseguridad

La IA generativa cambia las reglas del juego:

- Permite ataques más rápidos y masivos. Lo que antes tardaba días, ahora se hace en minutos.
- Las defensas tradicionales ya no bastan. Antes se detectaban ataques por patrones conocidos, ahora los atacantes los cambian constantemente.
- Aumenta la presión sobre los profesionales de ciberseguridad. No solo hay más ataques, también son más sofisticados.

Aun así, no todo es malo. Estos cambios también obligan a mejorar estrategias, implementar sistemas de detección por comportamiento y capacitar mejor a los equipos.

2.4 Comparación con amenazas tradicionales

Antes, los ataques eran más previsibles. Dependían de la intervención humana y se repetían patrones claros. Ahora, la IA permite automatizar y personalizar ataques. Esto significa que:

- Más personas pueden ejecutar ataques sin ser expertos.
- Los ataques cambian constantemente, dificultando su detección.

- Se necesita invertir en nuevas tecnologías de defensa y formación del personal.

En otras palabras, los ataques tradicionales eran como balas, los de IA generativa son flechas que cambian de dirección mientras vuelan. Sí, suena dramático, pero es una buena analogía.

2.5 Lagunas de investigación

A pesar de todo lo que se ha escrito, hay huecos importantes:

- Pocos estudios analizan cómo los atacantes combinan varias técnicas de IA generativa.
- Falta información sobre eficacia de contramedidas frente a ataques adaptativos.
- No hay muchos estudios sobre impacto en infraestructuras críticas, como energía o transporte.

Eso significa que todavía hay mucho que investigar. Y sí, esto es una oportunidad para aprender y proponer soluciones.

2.6 Perspectiva futura

Todos sabemos que la IA generativa va a seguir avanzando. Esto podría:

- Generar ataques más complejos y difíciles de detectar.
- Crear deepfakes más convincentes, que sean imposibles de distinguir de la realidad.
- Automatizar la suplantación de identidad a gran escala.

De igual manera, también habrá herramientas defensivas que usen IA. La diferencia es que la carrera entre atacantes y defensores será más rápida y más difícil de controlar. Por eso, entender estos riesgos ahora es clave.

3. Metodología planteada

3.1 Enfoque teórico-descriptivo (análisis documental)

Para este proyecto, el enfoque elegido es teórico-descriptivo, basado en análisis documental. Es decir, no vamos a hacer experimentos prácticos ni encuestas, sino que vamos a examinar información existente, compararla y extraer conclusiones sobre cómo la IA generativa está afectando la ciberseguridad.

La idea es entender patrones, impactos y tendencias sin necesidad de probar ataques nosotros mismos, porque eso sería ilegal y peligroso. Se deben mirar estudios, informes, casos reales y artículos académicos para ver qué está pasando y qué riesgos emergen. Honestamente, es más seguro y también más interesante, porque permite ver muchos casos diferentes y sacar conclusiones más generales.

El análisis documental permite, además, identificar lagunas de conocimiento, que son esos puntos donde la información aún es escasa. Y sí, en este tema hay varias, sobre todo en ataques automatizados o en infraestructuras críticas. También ayuda a organizar la información y a tener una base sólida para después proponer recomendaciones o alertas que podrían ser útiles para equipos de ciberseguridad o investigadores futuros.

3.2 Fuentes

Las fuentes que vamos a usar son variadas, para tener un panorama más completo:

- Artículos académicos: Publicaciones revisadas por expertos sobre IA generativa, deepfakes y ciberseguridad. Esto nos da un soporte sólido y confiable.

- Informes de ciberseguridad: Por ejemplo, los de Europol, Kaspersky o Cisco ([Cisco, 2024](#)). Son útiles porque incluyen datos recientes y análisis de tendencias, algo que los papers académicos no siempre reflejan.
- Estudios de caso: Casos concretos de ataques, fraudes o brechas de seguridad donde se haya identificado el uso de IA generativa. Esto ayuda a ver cómo los conceptos se aplican en la vida real, y además da ejemplos concretos para ilustrar los riesgos.

La mejor opción es usar una combinación de estas fuentes para contrastarlas entre sí, y no depender solo de un tipo de documento. Así se evita sesgo y se obtiene un análisis más completo. Además, tener distintos tipos de fuentes permite cubrir desde lo técnico hasta lo práctico, que es justo lo que necesitamos para entender un fenómeno tan amplio como la IA generativa en ciberseguridad.

3.3 Métodos de análisis

El análisis documental no se limita a leer y resumir información. El tema es un poco más organizada. Vamos a aplicar varias técnicas complementarias para entender mejor cómo la IA generativa impacta en ciberseguridad.

3.3.1 Revisión comparativa

Primero, haremos una revisión comparativa. Esto significa que vamos a comparar información entre distintos tipos de fuentes. Por ejemplo, un informe de Europol puede dar datos sobre la cantidad de ataques de phishing automatizados, mientras un artículo académico explica cómo funciona técnicamente la generación de estos ataques. Al contrastar ambos puntos de vista, podemos ver coincidencias, diferencias y lagunas, y eso nos ayuda a interpretar mejor los riesgos reales.

Además, la revisión comparativa permite identificar tendencias a lo largo del tiempo. Por ejemplo, podemos analizar cómo han evolucionado los deepfakes en los últimos tres años: desde vídeos básicos que se veían falsos, hasta audios clonados de ejecutivos que pueden engañar a bancos y empresas ([MIT Technology](#)

[Review, 2023](#)). Esto nos da un panorama más completo y actualizado, que es justo lo que necesitamos.

3.3.2 Análisis de tendencias

Otra técnica que vamos a usar es el análisis de tendencias. Esto implica observar patrones en los ataques y evaluar su evolución. Por ejemplo, la frecuencia de correos de phishing generados por IA ha aumentado significativamente desde 2022 ([Kapersky, 2025](#)). Es importante saber que también podemos detectar tendencias emergentes, como la combinación de deepfakes con ingeniería social, o ataques automatizados a cuentas corporativas en redes sociales.

Este análisis no solo nos permite ver lo que ya está pasando, sino que también ayuda a predecir riesgos futuros. No es que podamos decir con certeza qué pasará, pero sí podemos estimar qué tipos de ataques podrían volverse más frecuentes y cuáles podrían ser los más dañinos. Por ejemplo, ataques combinados que incluyan malware generado por IA más deepfakes para manipular empleados de empresas grandes.

3.3.3 Clasificación de amenazas

Además, vamos a clasificar los ataques según tres criterios: impacto, facilidad de ejecución y potencial de propagación. Esto permite organizar la información de manera más clara. Por ejemplo:

- Un correo de phishing sencillo, aunque sea automatizado, tiene bajo impacto individual, pero puede propagarse rápido.
- Un deepfake que permite fraude financiero tiene alto impacto, pero es más complejo de generar.

- Malware asistido por IA puede ser relativamente fácil de crear para un atacante con conocimientos básicos, pero su propagación depende de otros factores.

La clasificación ayuda a priorizar qué amenazas requieren más atención y recursos, algo muy útil para los equipos de ciberseguridad.

3.3.4 Identificación de riesgos emergentes

Un aspecto que considero muy importante es identificar riesgos emergentes. Por ejemplo, la IA generativa podría usarse en el futuro para atacar infraestructuras críticas, como redes eléctricas, sistemas de transporte o bancos. Aunque no haya muchos casos reportados, es probable que la tendencia siga en aumento.

Otro riesgo emergente es la automatización de ataques combinados. Por ejemplo, un atacante podría usar IA para generar correos de phishing, deepfakes y malware de manera simultánea. Eso aumentaría la eficacia del ataque y reduciría el tiempo necesario para ejecutarlo.

La idea es que, al identificar estos riesgos, podamos informar a profesionales y empresas sobre posibles escenarios antes de que ocurran, lo cual es más proactivo que solo reaccionar a incidentes después de que suceden.

3.4 Criterios de selección de fuentes

No todas las fuentes son igual de útiles. Por eso, establecemos algunos criterios de selección:

- Relevancia: Solo se incluyen fuentes que traten directamente sobre IA generativa y ciberseguridad. Por ejemplo, un estudio sobre deepfakes o malware asistido por IA.
- Actualidad: Prioridad a artículos y reportes de los últimos cinco años, porque este campo cambia muy rápido.

- Fiabilidad: Informes de organizaciones reconocidas (Europol, Kaspersky, Cisco) o artículos revisados por pares.
- Cobertura: Buscamos diversidad, que incluya análisis técnico, casos prácticos y estadísticas, para tener una visión completa.

Esto nos asegura que el análisis sea consistente y fiable, sin depender de información desactualizada o incompleta.

3.5 Limitaciones del método

Como todo estudio, este enfoque tiene limitaciones. No podemos probar ataques reales, así que no se puede medir la efectividad real de cada técnica en entornos controlados. También dependemos de la información disponible, que puede estar incompleta o sesgada. Por ejemplo, los informes a veces solo muestran ataques detectados, no los que no se reportaron.

Además, algunos riesgos futuros solo se pueden estimar, no confirmar. Esto significa que nuestras conclusiones sobre amenazas emergentes son más bien proyecciones, basadas en patrones observados y opiniones de expertos. Aun así, creo que sigue siendo útil para entender el panorama y preparar estrategias preventivas.

3.6 Justificación de la elección metodológica y descarte de alternativas

Para este proyecto se ha elegido un enfoque teórico-descriptivo basado en análisis documental. Este enfoque no solo permite estudiar patrones y tendencias actuales, sino que además es el método más adecuado teniendo en cuenta las limitaciones éticas, legales y técnicas del tema. El estudio de ciberataques que involucran IA generativa implica riesgos significativos: reproducir ataques reales, incluso en entornos controlados, podría incurrir en violaciones éticas, normativas e incluso legales, especialmente si se generara código malicioso o deepfakes funcionales.

Por ese motivo, se descartaron otras metodologías, lo cual no estaba explicado en la versión inicial y es clave para justificar la decisión del método elegido:

- Experimentación práctica (penetration testing, creación de malware, generación de deepfakes): Aunque podría ofrecer datos directos, fue rechazada por razones éticas y de seguridad. Replicar ataques reales supone un riesgo elevado, especialmente en el contexto académico.
- Simulaciones técnicas con herramientas de IA: También descartadas porque muchos modelos generativos tienen restricciones de seguridad que impiden generar malware o contenido dañino. Además, una simulación parcial carecería de validez si no imita escenarios reales con precisión.
- Investigación cuantitativa basada en encuestas masivas: Se consideró, pero se descartó porque los profesionales de ciberseguridad no siempre pueden revelar información operativa o interna de forma segura. Además, la tasa de respuesta suele ser baja sin acceso directo a empresas del sector.
- Entrevistas a expertos en ciberseguridad: Aunque es un método válido y podría considerarse en la segunda fase del proyecto, se descartó para esta primera parte por limitaciones temporales y logísticas. Sin embargo, se deja abierta la posibilidad de utilizar entrevistas en la entrega final (AB2), tal y como recomienda el profesor.

3.7 Cierre de la primera parte

En resumen, esta primera parte de la metodología establece las bases para todo el análisis del proyecto. Hemos definido que el enfoque será teórico-descriptivo, apoyado en análisis documental, y que las fuentes incluirán artículos académicos, informes de ciberseguridad y estudios de caso. También hemos explicado cómo se aplicarán técnicas como la revisión comparativa, el análisis de tendencias, la clasificación de amenazas y la identificación de riesgos emergentes.

Sabemos es que hasta aquí tenemos una estructura sólida, pero todavía quedan elementos por desarrollar. En la segunda parte abordaremos con más detalle los criterios de selección de fuentes, técnicas más específicas de análisis y limitaciones, además de una reflexión final sobre cómo todo esto nos ayudará a responder la pregunta de investigación.

De esta forma, dejamos claro qué se ha hecho y qué falta, asegurando que la metodología sea transparente y replicable, y al mismo tiempo manteniendo la continuidad del proyecto para completarlo de manera organizada en la siguiente sección.

4. Progreso del proyecto

Durante esta fase intermedia del proyecto se ha avanzado de manera sustancial en el análisis documental planteado inicialmente. Aunque el enfoque general se mantiene, el trabajo ha comenzado a centrarse en la identificación y estudio de casos reales donde la inteligencia artificial generativa ha desempeñado un papel significativo en ciberataques recientes. Este tipo de evidencias prácticas está permitiendo observar con más claridad cómo se materializan las amenazas descritas en el marco teórico, y también facilita una comprensión más profunda del impacto real que están teniendo en entornos corporativos y sociales.

El progreso del proyecto no se ha limitado únicamente a recopilar información. También se ha ampliado la variedad de fuentes revisadas, incorporando informes técnicos, artículos especializados y documentación publicada en los últimos dos años. Esta ampliación era necesaria porque el ritmo de evolución de la IA generativa es tan rápido que apoyarse solo en fuentes del AB1 habría provocado un cierto desfase. Además, la revisión de estos nuevos documentos ha permitido encontrar patrones interesantes, como el uso repetido de modelos generativos en campañas de phishing dirigido o la proliferación de deepfakes utilizados para extorsionar o manipular a empleados de departamentos financieros en empresas.

Otro aspecto relevante de este progreso es que algunos temas que inicialmente parecían secundarios han adquirido más importancia a medida que avanzaba la investigación. Por ejemplo, el uso de audio deepfake en fraudes financieros ha demostrado ser más frecuente y técnicamente más accesible de lo que sugerían las fuentes revisadas en el AB1. También se han detectado varios casos de malware asistido por IA que, aunque todavía no alcanzan una complejidad extrema, sí muestran una tendencia preocupante hacia la automatización de tareas ofensivas que antes requerían habilidades avanzadas.

Durante este avance se han encontrado también ciertas limitaciones. La principal es que no todos los casos reales están documentados con suficiente detalle técnico, ya que muchas empresas evitan publicar información completa para no exponer vulnerabilidades internas. Esto ha obligado a contrastar varias fuentes para obtener una visión más precisa, comparando datos y verificando la fiabilidad antes de incorporarlos al proyecto. Aun con esas limitaciones, el progreso ha sido sólido y ha permitido reunir una base de evidencias suficientemente rica como para iniciar el análisis interpretativo que se desarrollará más adelante.

5. Ajustes realizados al proyecto

A medida que se fue profundizando en la documentación y se identificaron casos reales relevantes, fue necesario introducir varios ajustes metodológicos y operativos para mantener la robustez del estudio y su utilidad práctica. Primero, se ha refinado el criterio de selección de casos: en lugar de limitarse a ejemplos genéricos sobre IA, se priorizaron incidentes con evidencias públicas suficientes que permitieran analizar con cierto detalle la técnica usada, el vector de ataque y las consecuencias observadas. Este cambio reduce el riesgo de basar conclusiones en anécdotas o en informes incompletos, y permite una comparación más fiable entre casos.

En segundo lugar, dado que la literatura y los informes oficiales muestran una aceleración en el uso de herramientas generativas en ataques ([SlashNext, 2024](#)) (por ejemplo, para phishing y para creación de contenido sintético), se decidió incorporar un proceso de verificación cruzada de fuentes más estricto. Es decir: cada caso incluido debe estar respaldado por al menos dos fuentes independientes (por ejemplo, un informe técnico y una noticia o un comunicado de seguridad). Esto

se ha hecho porque, en muchos incidentes, las empresas no ofrecen detalles técnicos completos por motivos de confidencialidad, lo que obliga a contrastar antes de extraer conclusiones firmes

Un tercer ajuste importante ha sido introducir una categoría de “grado de evidencia” para cada caso analizado. No todos los incidentes presentan la misma calidad informativa: algunos están documentados con informes forenses, otros solo con comunicados de prensa; por tanto, cada caso ahora lleva una etiqueta que va desde “evidencia sólida” hasta “evidencia limitada”. Esta clasificación ayuda a matizar las interpretaciones y evita generalizaciones apresuradas. Además, permite al lector distinguir entre hallazgos bien confirmados y observaciones preliminares que necesitan más comprobación.

Otro ajuste metodológico se refiere al alcance temporal de las fuentes. Inicialmente se priorizaron textos de los últimos cinco años, pero al comprobar la velocidad de evolución del fenómeno se redujo ese umbral para los casos y reportes técnicos a los últimos tres años, y en muchos apartados incluso a los últimos dos. Esto asegura que los resultados iniciales sean relevantes frente a la realidad actual, donde herramientas y tácticas cambian en meses. No es una elección arbitraria: Europol y otros organismos recomiendan enfocar el análisis hacia fuentes recientes debido a la rápida aparición de nuevos vectores y técnicas ([Europol, 2024](#)) .

En cuanto a la posible incorporación de investigación primaria que el profesor ha sugerido reforzar en la segunda entrega se han diseñado ahora pasos preparatorios. En esta fase intermedia se ha descartado realizar experimentación práctica (p. ej. generación activa de malware o deepfakes) por motivos éticos y legales ([NIST, 2023](#)); en su lugar se plantea en la fase siguiente la realización de entrevistas semiestructuradas con profesionales del sector y la elaboración de un breve cuestionario dirigido a responsables de seguridad en empresas medianas y grandes. Estas actividades permitirán recoger datos cualitativos y contrastar las hipótesis surgidas del análisis documental, sin poner en riesgo la integridad del estudio ni violar normas éticas.

También se ha introducido un ajuste en la presentación de resultados: para cada caso real se incluirá ahora un pequeño esquema técnico (vector de ataque, herramienta IA implicada, efectos sobre la víctima, medidas de mitigación

aplicadas) y un comentario interpretativo sobre la probabilidad de replicación a gran escala. Esto facilita que el análisis no sea meramente narrativo, sino que muestre elementos replicables y comparables entre incidentes, y que permita identificar tendencias por ejemplo, si cierto tipo de deepfake o de phishing asistido por IA está repitiéndose con variaciones claras. La literatura reciente coincide en que estos patrones son cada vez más importantes para anticipar riesgos.

Finalmente, se ha revisado el equilibrio entre profundidad técnica y claridad expositiva. Muchos informes técnicos son densos y difíciles de sintetizar para una audiencia mixta; por ello, se ha decidido mantener un lenguaje técnico cuando sea necesario, pero acompañarlo de resúmenes ejecutivos y tablas que resuman las implicaciones principales para equipos de seguridad. Este compromiso busca que el proyecto sea útil tanto para un lector académico como para un profesional de ciberseguridad que necesite conclusiones prácticas y aplicables inmediatamente. En la práctica, esto ha supuesto rehacer algunos párrafos del AB1 y ajustar el nivel de detalle en la documentación de casos.

En resumen, los ajustes realizados tienen como objetivo mejorar la validez, fiabilidad y relevancia del estudio. No modifican la hipótesis central ni el enfoque general; más bien, afinan las herramientas metodológicas para que los resultados iniciales que se presentarán a continuación sean más robustos y mejor contextualizados. Estos cambios responden además a recomendaciones observadas en la bibliografía especializada y en los informes institucionales, que insisten en la necesidad de metodologías adaptativas frente a la rápida evolución de las amenazas basadas en IA.

6. Resultados Iniciales y Análisis de Casos

Tras completar la fase de recolección documental y aplicar los filtros de fiabilidad descritos en la metodología, el análisis de los datos arroja una primera conclusión contundente: la teoría sobre los riesgos de la IA generativa se ha materializado mucho más rápido de lo que las predicciones académicas de hace dos años anticipaban. Ya no estamos hablando de escenarios hipotéticos o pruebas de concepto en laboratorios de investigación; los resultados muestran que estas herramientas son ahora parte activa y cotidiana del arsenal ofensivo.

A continuación, se presentan los hallazgos divididos por vector de ataque, integrando estadísticas recientes y casos de estudio que demuestran el cambio cualitativo en las amenazas.

6.1. Ingeniería Social Automatizada: El salto de calidad y volumen en el Phishing

El hallazgo más significativo de esta investigación reside en la transformación del phishing. Históricamente, la defensa contra el phishing se basaba en identificar errores humanos en el atacante: mala gramática, formatos inconsistentes o traducciones automáticas de baja calidad. Sin embargo, los datos recopilados indican que esa "ventana de oportunidad" para la detección se ha cerrado.

Según el último informe sobre el estado del phishing de [SlashNext \(2024\)](#), se ha registrado un aumento vertiginoso del 4.151% en el volumen de correos maliciosos desde el lanzamiento de ChatGPT a finales de 2022. Este dato es revelador porque correlaciona directamente la disponibilidad de Modelos de Lenguaje Grande (LLMs) con la capacidad de disparo de los ciberdelincuentes. No es simplemente que haya más ataques, es que la IA ha eliminado el cuello de botella de la redacción manual.

Además, la calidad de estos ataques ha mejorado sustancialmente. El análisis de [Kaspersky \(2025\)](#) señala que sus sistemas bloquearon más de 893 millones de intentos de phishing durante el último periodo analizado, lo que representa un incremento del 26% respecto al año anterior. Lo preocupante no es solo el número, sino la sofisticación: los correos generados por IA ahora son capaces de imitar el tono corporativo, utilizar jerga específica de la industria y carecen de los errores ortográficos que antes servían de alerta temprana para los empleados.

Esto confirma que la IA generativa ha democratizado la capacidad de realizar spear-phishing (phishing dirigido). Anteriormente, personalizar un correo para un directivo requería horas de investigación y redacción cuidadosa. Hoy, herramientas derivadas de modelos abiertos permiten a un atacante generar cientos de variantes personalizadas en segundos, aumentando la tasa de éxito de forma exponencial.

6.2. Fraude Financiero mediante Deepfakes de Audio y Video

Si el phishing representa el ataque por volumen, los deepfakes representan el ataque de alto impacto. Durante la revisión de casos, se ha identificado un incidente que marca un antes y un después en la ciberseguridad corporativa: el caso de la firma multinacional Arup.

Tal y como reporta [Check Point Research \(2024\)](#), un empleado del departamento financiero de esta compañía fue engañado para realizar transferencias por valor de 25 millones de dólares tras asistir a una videollamada. Lo aterrador de este caso es que todos los participantes en la llamada, excepto la víctima, eran recreaciones deepfake generadas por IA que imitaban la apariencia y la voz del director financiero y otros colegas. Este nivel de engaño, que supera cualquier barrera de concienciación tradicional, demuestra que la verificación visual ya no es garantía de identidad.

Pero el video no es el único riesgo. Los datos sugieren que el audio es una amenaza aún más insidiosa y extendida. Un análisis citado por Check Point indica que el fraude mediante voz sintética aumentó un 173% en el último año. La tecnología actual permite clonar la voz de una persona con apenas unos segundos de audio de referencia, que a menudo se extraen de redes sociales o vídeos corporativos públicos. Esto pone en jaque los sistemas de autenticación biométrica por voz que muchos bancos habían empezado a implementar, obligando a repensar los protocolos de seguridad telefónica desde cero.

6.3. Desarrollo de Malware y la reducción de barreras técnicas

Finalmente, en el ámbito del software malicioso, los resultados muestran una tendencia clara hacia la asistencia técnica. Aunque todavía no se ha detectado un malware "autónomo" que se reescriba a sí mismo en tiempo real de forma perfecta, la IA está actuando como un copiloto eficaz para los desarrolladores de malware.

Los sistemas de detección de [Kaspersky \(2025\)](#) identificaron una media de 467.000 nuevos archivos maliciosos cada día durante el último año, un aumento del 14% frente al periodo anterior. Este incremento sugiere que la IA está ayudando a los atacantes a generar variaciones de código con mayor rapidez, permitiéndoles eludir las firmas de los antivirus tradicionales mediante técnicas de ofuscación automatizada.

[Europol \(2024\)](#), en su evaluación de amenazas (IOCTA), advierte que esta tendencia continuará. La IA permite a actores con pocos conocimientos técnicos escribir scripts funcionales o mejorar código defectuoso, bajando la barrera de entrada al cibercrimen. Ya no hace falta ser un experto en C++ o ensamblador para lanzar una campaña de malware efectiva; basta con saber preguntar al modelo de IA adecuado.

7. Discusión: Interpretación de los hallazgos y contraste teórico

Una vez expuestos los datos y los casos recientes, es necesario detenerse a interpretar qué significan realmente para el panorama de la ciberseguridad actual. Si retomamos la pregunta de investigación planteada al inicio de este proyecto *¿Cómo están usando los atacantes la IA generativa y qué impacto futuro tiene?* la respuesta que emerge del análisis es bastante más compleja y alarmante de lo que sugería la teoría inicial.

A continuación, discuto las cuatro implicaciones críticas que se derivan de los resultados obtenidos y que redefinen nuestra comprensión del problema.

7.1. La paradoja de la "Democratización del Cibercrimen"

En la revisión de literatura (sección 2.2.3), citamos estudios teóricos que advertían sobre cómo la IA podría ayudar a crear malware. Sin embargo, los resultados del análisis de amenazas de 2024 ([Kaspersky](#), [Europol](#)) confirman que esto ya no es una advertencia futura, sino una realidad operativa.

Lo que estamos viendo es una reducción drástica de la barrera de entrada. Tradicionalmente, ser un ciberdelincuente peligroso requería años de aprendizaje técnico profundo. Hoy, los hallazgos sugieren que herramientas como ChatGPT (o sus versiones sin censura en la Dark Web, como WormGPT) actúan como "mentores" instantáneos. Esto crea una asimetría peligrosa: mientras que los equipos defensivos necesitan formación constante y costosa, los atacantes pueden suplir su falta de habilidades con asistencia sintética.

Esto cambia radicalmente el perfil de riesgo para las empresas: ya no solo deben preocuparse por los grupos de hackers de élite (APTs), sino por una masa creciente

de atacantes de bajo nivel que ahora poseen capacidades ofensivas de nivel medio gracias a la IA.

7.2. El fin de la concienciación tradicional

Quizás el punto más crítico de esta discusión es que los datos sobre phishing y deepfakes nos obligan a admitir que las estrategias clásicas de formación de empleados están quedándose obsoletas.

Durante años, la industria ha enseñado a los usuarios a buscar "señales de alerta": faltas de ortografía, saludos genéricos o vídeos con movimientos extraños. Pero, como vimos en el caso de Arup y en las estadísticas de [SlashNext](#), la IA generativa ha eliminado precisamente esas señales. Si un correo de phishing es gramaticalmente perfecto y un audio clonado suena idéntico al del CEO, ¿cómo podemos exigirle al empleado que lo detecte?

La interpretación de estos hallazgos sugiere que la responsabilidad de la detección debe trasladarse progresivamente del humano a la tecnología. No es viable culpar a una persona por caer en un engaño que es técnicamente indistinguible de la realidad.

7.3. Velocidad vs. Precisión: La nueva carrera armamentística

Al contrastar los resultados actuales con la literatura del AB1, se observa una discrepancia significativa en los tiempos. Los artículos académicos de 2022-2023 hablaban de estos riesgos como algo a medio plazo, pero la realidad de 2024/2025 muestra que la adopción ha sido inmediata.

El análisis de tendencias indica que los atacantes tienen una ventaja estructural: la agilidad. Mientras una empresa tarda meses en aprobar presupuestos e implementar un nuevo sistema de defensa, un ciberdelincuente puede adoptar una nueva herramienta generativa en una tarde. Esta brecha de velocidad es lo que está permitiendo el aumento masivo en las tasas de éxito de los ataques de ingeniería social que hemos documentado anteriormente.

7.4. Hacia un cambio de paradigma defensivo

Finalmente, la evidencia recopilada apunta a una conclusión inevitable: las herramientas defensivas actuales no están diseñadas para este nuevo tipo de amenaza. Los antivirus tradicionales buscan firmas de código conocidas, pero la IA genera código polimórfico que cambia constantemente. Los protocolos de verificación de voz asumen que la voz es única, pero la IA ha roto esa asunción.

Por lo tanto, la discusión no puede quedarse en el diagnóstico. La gravedad de los hallazgos hace evidente que el mero análisis de los ataques es insuficiente si no va acompañado de una propuesta de mitigación adaptada. Esto justifica la necesidad de formular, en la siguiente sección de este trabajo, un conjunto de estrategias de defensa (técnicas y procedimentales) que superen el enfoque reactivo tradicional y abracen modelos como Zero Trust ([IBM 2024](#)). Ya no se trata de preguntar "si" nos atacarán con IA, sino de rediseñar nuestros protocolos asumiendo que ya lo están haciendo.

8. Conclusiones Preliminares de la Fase Intermedia

Al llegar a este punto intermedio del proyecto, y retomando la pregunta de investigación sobre el uso ofensivo de la IA generativa, el análisis realizado permite extraer varias conclusiones provisionales que guiarán las siguientes etapas del trabajo.

En primer lugar, la evidencia recopilada hasta la fecha sugiere que la democratización de la sofisticación es un hecho consumado. Los datos analizados en esta fase muestran que la barrera técnica para ejecutar ataques complejos (como *phishing* contextualizado) ha desaparecido prácticamente. Lo que al inicio del estudio se planteaba como una hipótesis teórica, se ha confirmado mediante los reportes de incidentes de 2024: la calidad de los ataques masivos ha aumentado drásticamente gracias a la asistencia de LLMs.

En segundo lugar, se observa una brecha crítica en la defensa. Mientras que las herramientas ofensivas evolucionan a ritmo semanal, las estrategias defensivas que hemos revisado parecen ir un paso por detrás, dependiendo todavía en exceso del factor humano. Esto refuerza la necesidad de profundizar, en las próximas entregas, en la viabilidad técnica de las soluciones *Zero Trust* que hemos esbozado en la propuesta de mitigación.

Por último, se concluye provisionalmente que el impacto futuro no dependerá tanto de la tecnología en sí, sino de la velocidad de adopción. La ventaja actual de los atacantes reside en su agilidad; por tanto, el resto de la investigación deberá

centrarse en cómo las organizaciones pueden automatizar sus respuestas para cerrar esa ventana de tiempo.

9. Revisión del Progreso y Planificación Futura

Para cerrar esta segunda entrega (AB2), es necesario evaluar el estado actual del proyecto y definir la hoja de ruta para las fases finales (AB3 y Entrega Final).

Evaluación del trabajo realizado La metodología de análisis documental ha demostrado ser efectiva para construir una base sólida de conocimiento sobre las amenazas actuales. La decisión de descartar la experimentación práctica por motivos éticos y centrarse en el análisis de casos reales ha permitido avanzar sin riesgos legales, obteniendo resultados que son coherentes con la literatura más reciente. Se ha logrado cumplir con los objetivos específicos de identificar vectores de ataque y proponer contramedidas iniciales.

Ajustes para las siguientes fases, Sin embargo, el trabajo presenta áreas que requieren mayor desarrollo en las próximas entregas. Ahora que se han identificado las estrategias de mitigación (Defensa tecnológica y *Zero Trust*), el objetivo para la siguiente fase será detallar **cómo** se pueden implementar estas soluciones de manera realista en diferentes tipos de organizaciones, analizando sus costes y barreras de entrada.

Próximos pasos De cara al tercer entregable y a la finalización del proyecto, el trabajo se centrará en:

- Refinar la propuesta de mitigación, contrastándola con marcos de trabajo estándar (como NIST o ISO) para darle mayor validez profesional.
- Ampliar la discusión sobre las implicaciones éticas y legales del uso de IA defensiva, un aspecto que solo se ha tocado superficialmente en esta fase.
- Sintetizar todos los hallazgos para elaborar un conjunto final de recomendaciones que responda de manera integral a la pregunta de investigación.

De esta forma, el proyecto se mantiene en curso, con una base teórica y práctica ya establecida, y con una dirección clara para lograr una conclusión robusta en la entrega final.

10. Bibliografía

- Check Point Research (2024). *Deepfake Cyber Security Threats*. [cite_start]Disponible en: <https://www.checkpoint.com/cyber-hub/threat-prevention/what-is-malware/deepfake-cyber-security-threats/>
- Cisco (2024). *2024 Cisco Cybersecurity Readiness Index*. [cite_start]Disponible en: <https://newsroom.cisco.com/c/r/newsroom/en/us/a/y2024/m03/cybersecurity-readiness-index-2024.html>
- CrowdStrike (2024). *Global Threat Report 2024*. Disponible en: <https://www.crowdstrike.com/global-threat-report/>
- Europol (2024). *Internet Organised Crime Threat Assessment (IOCTA) 2024*. [cite_start]Disponible en: <https://www.europol.europa.eu/publication-events/main-reports/internet-organised-crime-threat-assessment-iocta-2024>
- Google Cloud (2023). *FIDO2 and Passwordless Future*. Disponible en: <https://cloud.google.com/blog/products/identity-security/google-cloud-and-fido2-passwordless>
- IBM Security (2024). *Cost of a Data Breach Report 2024*. [cite_start]Disponible en: <https://www.ibm.com/reports/data-breach>
- Kaspersky (2025). *Ciberamenazas que imitan herramientas de inteligencia artificial aumentan 115% en 2025*. [cite_start]Disponible en: <https://latam.kaspersky.com/about/press-releases/ciberamenazas-que-imitan-herramientas-de-inteligencia-artificial-como-chatgpt-aumentan-115-en-2025-kaspersky>
- Microsoft (2023). *Cyber Signals: Shifting tactics driven by AI*. Disponible en: <https://www.microsoft.com/en-us/security/blog/2023/12/07/cyber-signals-shifting-tactics/>
- Microsoft (2024). *Combating Deepfakes: The C2PA Standard*. Disponible en: <https://blogs.microsoft.com/on-the-issues/2024/02/13/combating-deepfakes-c2pa-check-content-credentials/>
- MIT Technology Review (2023). *The rise of AI-generated cyber threats*. [cite_start]Disponible en: <https://www.technologyreview.com/2023/06/12/1072580/ai-generated-cyber-threats/>

- NIST (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. National Institute of Standards and Technology. [cite_start]Disponibile en: <https://www.nist.gov/itl/ai-risk-management-framework>
- SlashNext (2024). *The State of Phishing 2024*. [cite_start]Disponibile en: <https://slashnext.com/blog/the-state-of-phishing-2024/>