


FRONT PAGE

Nombre Alumno / DNI	Alejandro García Casado – 49158343Y
Título del Programa	2º PHE Cybersecurity
N.º Unidad y Título	UNIT 16 - Computing Research Project
Año académico	2025-2026
Profesor de la unidad	Amalio
Título del Assignment	AB Final
Día de emisión	24/05/2026
Día de entrega	24/05/2026
Declaración del estudiante	Certifico que la presentación del assignment es completamente mi propio trabajo y entiendo completamente las consecuencias del plagio. Entiendo que hacer una declaración falsa es una forma de mala práctica. Fecha: 24/05/2026 Firma del alumno: 

Plagio

El plagio es una forma particular de hacer trampa. El plagio debe evitarse a toda costa y los alumnos que infrinjan las reglas, aunque sea inocentemente, pueden ser sancionados. Es su responsabilidad asegurarse de comprender las prácticas de referencia correctas. Como alumno de nivel universitario, se espera que utilice las referencias adecuadas en todo momento y mantenga notas cuidadosamente detalladas de todas sus fuentes de materiales para el material que ha utilizado en su trabajo, incluido cualquier material descargado de Internet. Consulte al profesor de la unidad correspondiente o al tutor del curso si necesita más consejos.

Tabla de contenido

1. Introducción.....	2
1.1 Contextualización del auge de la IA generativa	2
1.2 Relevancia del tema en ciberseguridad	2
1.3 Problema central y justificación.....	3
1.4 Objetivos generales y específicos	3
1.5 Pregunta de investigación	4
1.6 Limitaciones del estudio.....	4
2. Revisión de la literatura	5
2.1 Qué es la IA generativa y cómo funciona.....	5
2.2 Casos recientes de su uso en ciberataques	6
2.2.1 Deepfakes.....	6
2.2.2 Phishing automatizado	6
2.2.3 Malware asistido por IA	6
2.2.4 Suplantación de identidad y redes sociales	7
2.3 Impacto de la IA generativa en ciberseguridad.....	7
2.4 Comparación con amenazas tradicionales.....	8
2.5 Lagunas de investigación	8
2.6 Perspectiva futura	9
3. Metodología planteada.....	9
3.1 Enfoque teórico-descriptivo (análisis documental)	9
3.2 Fuentes	10
3.3 Métodos de análisis.....	11
3.3.1 Revisión comparativa.....	11
3.3.2 Análisis de tendencias	12
3.3.3 Clasificación de amenazas	12
3.3.4 Identificación de riesgos emergentes	13
3.4 Criterios de selección de fuentes	13
3.5 Limitaciones del método	14
3.6 Justificación de la elección metodológica y descarte de alternativas	14
3.7 Cierre de la primera parte	15
4. Progreso del proyecto.....	16
5. Ajustes realizados al proyecto	17
6. Resultados Iniciales y Análisis de Casos	19
6.1. Ingeniería Social Automatizada: El salto de calidad y volumen en el Phishing.....	20

6.2. Fraude Financiero mediante Deepfakes de Audio y Video	21
6.3. Desarrollo de Malware y la reducción de barreras técnicas	21
7. Discusión: Interpretación de los hallazgos y contraste teórico.....	22
7.1. La paradoja de la "Democratización del Cibercrimen"	22
7.2. El fin de la concienciación tradicional	23
7.3. Velocidad vs. Precisión: La nueva carrera armamentística.....	24
7.4. Hacia un cambio de paradigma defensivo	24
8. Conclusiones Preliminares de la Fase Intermedia	25
9. Revisión del Progreso y Planificación Futura.....	25
10. Investigación primaria y validación cualitativa	26
11. Resultados avanzados y contraste con la literatura.....	28
12. Estrategias de mitigación y adaptación defensiva	30
12.1. La necesidad de cambiar el enfoque defensivo	30
12.2. Zero Trust y autenticación reforzada	31
12.3. IA defensiva y detección conductual	32
12.4. Formación y adaptación humana.....	33
13. Planificación de la comunicación y difusión de resultados	34
13.1. Comunicación en entornos académicos y técnicos	35
13.2. Comunicación hacia empresas y usuarios no especializados	35
13.3. Uso de formatos visuales y divulgativos	36
13.4. Importancia de la concienciación continua	37
14. Conclusiones	38
15. Futuras líneas de investigación.....	40
17. Reflexión crítica del proyecto	42
Bibliografía.....	44

1. Introducción

1.1 Contextualización del auge de la IA generativa

La inteligencia artificial generativa se ha hecho bastante conocida en los últimos años. Modelos como ChatGPT, DALL·E o Gemini pueden generar texto, imágenes, audio o incluso código a partir de simples instrucciones. Lo impresionante es que cualquiera puede acceder a estas herramientas mediante aplicaciones o APIs, sin necesidad de ser experto en programación.

Estas tecnologías no solo son populares, sino también muy potentes. Pueden imitar estilos de escritura, crear imágenes realistas o resumir información de manera sorprendente. Y sí, eso está bien para tareas creativas o productividad. Pero, como veremos, esa misma capacidad se puede usar para cosas malas. Por ejemplo, generar deepfakes, redactar correos de phishing o incluso crear fragmentos de código malicioso.

1.2 Relevancia del tema en ciberseguridad

Sabemos que, en ciberseguridad, la IA generativa cambia bastante las reglas del juego. Antes, los atacantes necesitaban habilidades técnicas o bastante tiempo para preparar un ataque convincente. Ahora, con estos modelos, pueden automatizar tareas y hacer ataques más realistas.

Informes recientes de Europol y Kaspersky indican que los ataques que usan IA generativa están creciendo y son más difíciles de detectar. Los sistemas de defensa tradicionales, como filtros de correo o antivirus, no siempre pueden seguir el ritmo. Así que sí, entender cómo se usa la IA generativa en ataques es importante, porque no es solo un riesgo futuro: ya está ocurriendo.

1.3 Problema central y justificación

El problema principal es entender cómo se usa la IA generativa para atacar y qué riesgos representa hoy y mañana. Honestamente, la literatura aún tiene huecos: hay muchos estudios sobre cómo la IA ayuda a defender, pero pocos que analicen su uso ofensivo.

La justificación es simple: la IA generativa es cada vez más accesible, los ataques se vuelven más sofisticados y las regulaciones no avanzan al mismo ritmo. Si no estudiamos esto ahora, las empresas y usuarios podrían quedarse atrás, sin defensas adecuadas.

Además, anticipar posibles futuros ataques ayuda a diseñar estrategias de prevención más sólidas.

1.4 Objetivos generales y específicos

Objetivo general:

Analizar cómo la IA generativa se usa como herramienta para ciberataques y qué implicaciones tiene para la seguridad digital.

Objetivos específicos:

- Explicar de forma clara las capacidades de los modelos de IA generativa que son relevantes para la seguridad.
- Revisar casos actuales de ataques usando IA: deepfakes, phishing automatizado, generación de malware y manipulación de información.
- Evaluar qué tan efectivas son las defensas actuales frente a estos ataques.
- Explorar escenarios futuros y proponer ideas generales de mitigación.

1.5 Pregunta de investigación

¿Cómo están usando los atacantes la IA generativa para crear nuevas formas de ciberataques y qué impacto podrían tener estas amenazas en la ciberseguridad en el futuro?

Esta pregunta guía todo el proyecto. Cada análisis, caso o conclusión que incluimos se relaciona con ella.

1.6 Limitaciones del estudio

Este trabajo se basa en revisión documental y análisis teórico, así que no haremos experimentos reales ni generaremos ataques con IA. Eso sería poco ético y arriesgado.

Otra limitación es la rapidez con la que cambian los modelos y técnicas de IA. Algunos estudios o datos recientes pueden quedar desactualizados en meses. Por eso, priorizamos referencias de los últimos dos o tres años y fuentes confiables.

Finalmente, aunque tocaremos aspectos legales y éticos, el enfoque principal es técnico y estratégico, tratando de mostrar qué está pasando y qué podría pasar, sin desviarnos demasiado en la teoría legal.

2. Revisión de la literatura

2.1 Qué es la IA generativa y cómo funciona

La IA generativa es un tipo de inteligencia artificial que puede crear contenido nuevo: texto, imágenes, audio o incluso código. Básicamente funciona aprendiendo patrones a partir de muchísimos datos. Por ejemplo, ChatGPT genera textos, DALL·E crea imágenes según lo que describas y Gemini mezcla texto e imagen.

La IA no “entiende” realmente lo que hace, solo sigue los patrones que ha aprendido. Por eso, a veces genera cosas raras o equivocadas. Pero esa misma capacidad para imitar y crear hace que sea un riesgo para la ciberseguridad. Alguien sin mucha experiencia técnica puede generar un correo de phishing convincente o un deepfake que engañe a otras personas. Honestamente, eso cambia mucho el panorama comparado con hace solo unos años.

2.2 Casos recientes de su uso en ciberataques

2.2.1 Deepfakes

Los deepfakes son contenidos falsos, vídeos o audios, que imitan personas reales. Se usan para engañar o extorsionar. Por ejemplo, hubo un caso en Reino Unido donde la voz de un director fue clonada para autorizar una transferencia bancaria. Suena un poco aterrador, ¿no? Lo que antes requería mucho tiempo y habilidades, ahora cualquiera con la herramienta adecuada puede intentarlo.

Además, los deepfakes no solo afectan a empresas; también pueden manipular la opinión pública o redes sociales. Por eso es importante entender cómo funcionan y qué medidas se pueden tomar, aunque todavía no hay soluciones 100% eficaces.

2.2.2 Phishing automatizado

Antes, un correo de phishing era fácil de detectar: frases raras, faltas de ortografía, errores de formato. Ahora la IA generativa puede escribir correos muy convincentes. Puede imitar a un compañero de trabajo, a un jefe o incluso a una empresa conocida. Esto hace que los ataques sean más efectivos y rápidos.

Por ejemplo, se han detectado campañas donde se generaban cientos de correos únicos en minutos, cada uno adaptado al receptor. Antes, solo un hacker con experiencia podía hacer algo así en unas horas o días. Esto también aumenta el riesgo de que más personas caigan en el engaño, porque el mensaje parece real.

2.2.3 Malware asistido por IA

Algunos investigadores han probado que la IA generativa puede ayudar a crear malware básico o scripts de ataque solo a partir de instrucciones de texto. Esto no significa que sea fácil crear ataques complejos, pero sí baja la barrera para generar malware. Y claro, eso significa que personas sin experiencia pueden montar algo peligroso.

Este tipo de malware puede adaptarse más rápido, cambiar su comportamiento y evadir detecciones tradicionales. No es perfecto todavía, pero sí es preocupante. Y sí, hace que los equipos de seguridad tengan que estar más atentos que antes.

2.2.4 Suplantación de identidad y redes sociales

La IA generativa también se usa para crear identidades falsas en redes sociales. Puede generar fotos, perfiles completos y hasta publicaciones coherentes. Esto se ha visto en campañas de desinformación o fraudes online.

Un ejemplo reciente: un ataque donde se crearon varios perfiles falsos en LinkedIn para enviar mensajes de phishing a empleados de empresas de tecnología. Los mensajes parecían totalmente legítimos. Incluso los sistemas automáticos tienen problemas para detectar esto.

2.3 Impacto de la IA generativa en ciberseguridad

La IA generativa cambia las reglas del juego:

- Permite ataques más rápidos y masivos. Lo que antes tardaba días, ahora se hace en minutos.
- Las defensas tradicionales ya no bastan. Antes se detectaban ataques por patrones conocidos, ahora los atacantes los cambian constantemente.
- Aumenta la presión sobre los profesionales de ciberseguridad. No solo hay más ataques, también son más sofisticados.

Aun así, no todo es malo. Estos cambios también obligan a mejorar estrategias, implementar sistemas de detección por comportamiento y capacitar mejor a los equipos.

2.4 Comparación con amenazas tradicionales

Antes, los ataques eran más previsibles. Dependían de la intervención humana y se repetían patrones claros. Ahora, la IA permite automatizar y personalizar ataques. Esto significa que:

- Más personas pueden ejecutar ataques sin ser expertos.
- Los ataques cambian constantemente, dificultando su detección.
- Se necesita invertir en nuevas tecnologías de defensa y formación del personal.

En otras palabras, los ataques tradicionales eran como balas, los de IA generativa son flechas que cambian de dirección mientras vuelan. Sí, suena dramático, pero es una buena analogía.

2.5 Lagunas de investigación

A pesar de todo lo que se ha escrito, hay huecos importantes:

- Pocos estudios analizan cómo los atacantes combinan varias técnicas de IA generativa.
- Falta información sobre eficacia de contramedidas frente a ataques adaptativos.
- No hay muchos estudios sobre impacto en infraestructuras críticas, como energía o transporte.

Eso significa que todavía hay mucho que investigar. Y sí, esto es una oportunidad para aprender y proponer soluciones.

2.6 Perspectiva futura

Todos sabemos que la IA generativa va a seguir avanzando. Esto podría:

- Generar ataques más complejos y difíciles de detectar.
- Crear deepfakes más convincentes, que sean imposibles de distinguir de la realidad.
- Automatizar la suplantación de identidad a gran escala.

De igual manera, también habrá herramientas defensivas que usen IA. La diferencia es que la carrera entre atacantes y defensores será más rápida y difícil de controlar. Por eso, entender estos riesgos ahora es clave.

3. Metodología planteada

3.1 Enfoque teórico-descriptivo (análisis documental)

Para este proyecto, el enfoque elegido es teórico-descriptivo, basado en análisis documental. Es decir, no vamos a hacer experimentos prácticos ni encuestas, sino que vamos a examinar información existente, compararla y extraer conclusiones sobre cómo la IA generativa está afectando la ciberseguridad.

La idea es entender patrones, impactos y tendencias sin necesidad de probar ataques nosotros mismos, porque eso sería ilegal y peligroso. Se deben mirar estudios, informes, casos reales y artículos académicos para ver qué está pasando y qué riesgos emergen. Honestamente, es más seguro y también más interesante, porque permite ver muchos casos diferentes y sacar conclusiones más generales.

El análisis documental permite, además, identificar lagunas de conocimiento, que son esos puntos donde la información aún es escasa. Y sí, en este tema hay varias, sobre todo en ataques automatizados o en infraestructuras críticas. También ayuda a organizar la información y a tener una base sólida para después proponer recomendaciones o alertas que podrían ser útiles para equipos de ciberseguridad o investigadores futuros.

3.2 Fuentes

Las fuentes que vamos a usar son variadas, para tener un panorama más completo:

- Artículos académicos: Publicaciones revisadas por expertos sobre IA generativa, deepfakes y ciberseguridad. Esto nos da un soporte sólido y confiable.
- Informes de ciberseguridad: Por ejemplo, los de Europol, Kaspersky o Cisco ([Cisco, 2024](#)). Son útiles porque incluyen datos recientes y análisis de tendencias, algo que los papers académicos no siempre reflejan.
- Estudios de caso: Casos concretos de ataques, fraudes o brechas de seguridad donde se haya identificado el uso de IA generativa. Esto ayuda a ver cómo los conceptos se aplican en la vida real, y además da ejemplos concretos para ilustrar los riesgos.

La mejor opción es usar una combinación de estas fuentes para contrastarlas entre sí, y no depender solo de un tipo de documento. Así se evita sesgo y se obtiene un análisis más completo. Además, tener distintos tipos de fuentes permite cubrir desde lo técnico hasta lo práctico, que es justo lo que necesitamos para entender un fenómeno tan amplio como la IA generativa en ciberseguridad.

3.3 Métodos de análisis

El análisis documental no se limita a leer y resumir información. El tema es un poco más organizada. Vamos a aplicar varias técnicas complementarias para entender mejor cómo la IA generativa impacta en ciberseguridad.

3.3.1 Revisión comparativa

Primero, haremos una revisión comparativa. Esto significa que vamos a comparar información entre distintos tipos de fuentes. Por ejemplo, un informe de Europol puede dar datos sobre la cantidad de ataques de phishing automatizados, mientras un artículo académico explica cómo funciona técnicamente la generación de estos ataques. Al contrastar ambos puntos de vista, podemos ver coincidencias, diferencias y lagunas, y eso nos ayuda a interpretar mejor los riesgos reales.

Además, la revisión comparativa permite identificar tendencias a lo largo del tiempo. Por ejemplo, podemos analizar cómo han evolucionado los deepfakes en los últimos tres años: desde vídeos básicos que se veían falsos, hasta audios clonados de ejecutivos que pueden engañar a bancos y empresas ([MIT Technology Review, 2023](#)). Esto nos da un panorama más completo y actualizado, que es justo lo que necesitamos.

3.3.2 Análisis de tendencias

Otra técnica que vamos a usar es el análisis de tendencias. Esto implica observar patrones en los ataques y evaluar su evolución. Por ejemplo, la frecuencia de correos de phishing generados por IA ha aumentado significativamente desde 2022 ([Kaspersky, 2025](#)). Es importante saber que también podemos detectar tendencias emergentes, como la combinación de deepfakes con ingeniería social, o ataques automatizados a cuentas corporativas en redes sociales.

Este análisis no solo nos permite ver lo que ya está pasando, sino que también ayuda a predecir riesgos futuros. No es que podamos decir con certeza qué pasará, pero sí podemos estimar qué tipos de ataques podrían volverse más frecuentes y cuáles podrían ser los más dañinos. Por ejemplo, ataques combinados que incluyan malware generado por IA más deepfakes para manipular empleados de empresas grandes.

3.3.3 Clasificación de amenazas

Además, vamos a clasificar los ataques según tres criterios: impacto, facilidad de ejecución y potencial de propagación. Esto permite organizar la información de manera más clara. Por ejemplo:

- Un correo de phishing sencillo, aunque sea automatizado, tiene bajo impacto individual, pero puede propagarse rápido.
- Un deepfake que permite fraude financiero tiene alto impacto, pero es más complejo de generar.
- Malware asistido por IA puede ser relativamente fácil de crear para un atacante con conocimientos básicos, pero su propagación depende de otros factores.

La clasificación ayuda a priorizar qué amenazas requieren más atención y recursos, algo muy útil para los equipos de ciberseguridad.

3.3.4 Identificación de riesgos emergentes

Un aspecto que considero muy importante es identificar riesgos emergentes. Por ejemplo, la IA generativa podría usarse en el futuro para atacar infraestructuras críticas, como redes eléctricas, sistemas de transporte o bancos. Aunque no haya muchos casos reportados, es probable que la tendencia siga en aumento.

Otro riesgo emergente es la automatización de ataques combinados. Por ejemplo, un atacante podría usar IA para generar correos de phishing, deepfakes y malware de manera simultánea. Eso aumentaría la eficacia del ataque y reduciría el tiempo necesario para ejecutarlo.

La idea es que, al identificar estos riesgos, podamos informar a profesionales y empresas sobre posibles escenarios antes de que ocurran, lo cual es más proactivo que solo reaccionar a incidentes después de que suceden.

3.4 Criterios de selección de fuentes

No todas las fuentes son igual de útiles. Por eso, establecemos algunos criterios de selección:

- Relevancia: Solo se incluyen fuentes que traten directamente sobre IA generativa y ciberseguridad. Por ejemplo, un estudio sobre deepfakes o malware asistido por IA.
- Actualidad: Prioridad a artículos y reportes de los últimos cinco años, porque este campo cambia muy rápido.
- Fiabilidad: Informes de organizaciones reconocidas (Europol, Kaspersky, Cisco) o artículos revisados por pares.
- Cobertura: Buscamos diversidad, que incluya análisis técnico, casos prácticos y estadísticas, para tener una visión completa.

Esto nos asegura que el análisis sea consistente y fiable, sin depender de información desactualizada o incompleta.

3.5 Limitaciones del método

Como todo estudio, este enfoque tiene limitaciones. No podemos probar ataques reales, así que no se puede medir la efectividad real de cada técnica en entornos controlados. También dependemos de la información disponible, que puede estar incompleta o sesgada. Por ejemplo, los informes a veces solo muestran ataques detectados, no los que no se reportaron.

Además, algunos riesgos futuros solo se pueden estimar, no confirmar. Esto significa que nuestras conclusiones sobre amenazas emergentes son más bien proyecciones, basadas en patrones observados y opiniones de expertos. Aun así, creo que sigue siendo útil para entender el panorama y preparar estrategias preventivas.

3.6 Justificación de la elección metodológica y descarte de alternativas

Para este proyecto se ha elegido un enfoque teórico-descriptivo basado en análisis documental. Este enfoque no solo permite estudiar patrones y tendencias actuales, sino que además es el método más adecuado teniendo en cuenta las limitaciones éticas, legales y técnicas del tema. El estudio de ciberataques que involucran IA generativa implica riesgos significativos: reproducir ataques reales, incluso en entornos controlados, podría incurrir en violaciones éticas, normativas e incluso legales, especialmente si se generara código malicioso o deepfakes funcionales.

Por ese motivo, se descartaron otras metodologías, lo cual no estaba explicado en la versión inicial y es clave para justificar la decisión del método elegido:

- Experimentación práctica (penetration testing, creación de malware, generación de deepfakes): Aunque podría ofrecer datos directos, fue rechazada por razones éticas y de seguridad. Replicar ataques reales supone un riesgo elevado, especialmente en el contexto académico.
- Simulaciones técnicas con herramientas de IA: También descartadas porque muchos modelos generativos tienen restricciones de seguridad que impiden generar malware o contenido dañino. Además, una simulación parcial carecería de validez si no imita escenarios reales con precisión.
- Investigación cuantitativa basada en encuestas masivas: Se consideró, pero se descartó porque los profesionales de ciberseguridad no siempre pueden revelar información operativa o interna de forma segura. Además, la tasa de respuesta suele ser baja sin acceso directo a empresas del sector.

- Entrevistas a expertos en ciberseguridad: Aunque es un método válido y podría considerarse en la segunda fase del proyecto, se descartó para esta primera parte por limitaciones temporales y logísticas. Sin embargo, se deja abierta la posibilidad de utilizar entrevistas en la entrega final (AB2), tal y como recomienda el profesor.

3.7 Cierre de la primera parte

En resumen, esta primera parte de la metodología establece las bases para todo el análisis del proyecto. Hemos definido que el enfoque será teórico-descriptivo, apoyado en análisis documental, y que las fuentes incluirán artículos académicos, informes de ciberseguridad y estudios de caso. También hemos explicado cómo se aplicarán técnicas como la revisión comparativa, el análisis de tendencias, la clasificación de amenazas y la identificación de riesgos emergentes.

Sabemos que hasta aquí tenemos una estructura sólida, pero todavía quedan elementos por desarrollar. En la segunda parte abordaremos con más detalle los criterios de selección de fuentes, técnicas más específicas de análisis y limitaciones, además de una reflexión final sobre cómo todo esto nos ayudará a responder la pregunta de investigación.

De esta forma, dejamos claro qué se ha hecho y qué falta, asegurando que la metodología sea transparente y replicable, y al mismo tiempo manteniendo la continuidad del proyecto para completarlo de manera organizada en la siguiente sección.

4. Progreso del proyecto

Durante esta fase intermedia del proyecto se ha avanzado de manera sustancial en el análisis documental planteado inicialmente. Aunque el enfoque general se mantiene, el trabajo ha comenzado a centrarse en la identificación y estudio de casos reales donde la inteligencia artificial generativa ha desempeñado un papel significativo en ciberataques recientes. Este tipo de evidencias prácticas está permitiendo observar con más claridad cómo se materializan las amenazas descritas en el marco teórico, y también facilita una comprensión más profunda del impacto real que están teniendo en entornos corporativos y sociales.

El progreso del proyecto no se ha limitado únicamente a recopilar información. También se ha ampliado la variedad de fuentes revisadas, incorporando informes técnicos, artículos especializados y documentación publicada en los últimos dos años. Esta ampliación era necesaria porque el ritmo de evolución de la IA

generativa es tan rápido que apoyarse solo en fuentes del AB1 habría provocado un cierto desfase. Además, la revisión de estos nuevos documentos ha permitido encontrar patrones interesantes, como el uso repetido de modelos generativos en campañas de phishing dirigido o la proliferación de deepfakes utilizados para extorsionar o manipular a empleados de departamentos financieros en empresas.

Otro aspecto relevante de este progreso es que algunos temas que inicialmente parecían secundarios han adquirido más importancia a medida que avanzaba la investigación. Por ejemplo, el uso de audio deepfake en fraudes financieros ha demostrado ser más frecuente y técnicamente más accesible de lo que sugerían las fuentes revisadas en el AB1. También se han detectado varios casos de malware asistido por IA que, aunque todavía no alcanzan una complejidad extrema, sí muestran una tendencia preocupante hacia la automatización de tareas ofensivas que antes requerían habilidades avanzadas.

Durante este avance se han encontrado también ciertas limitaciones. La principal es que no todos los casos reales están documentados con suficiente detalle técnico, ya que muchas empresas evitan publicar información completa para no exponer vulnerabilidades internas. Esto ha obligado a contrastar varias fuentes para obtener una visión más precisa, comparando datos y verificando la fiabilidad antes de incorporarlos al proyecto. Aun con esas limitaciones, el progreso ha sido sólido y ha permitido reunir una base de evidencias suficientemente rica como para iniciar el análisis interpretativo que se desarrollará más adelante.

5. Ajustes realizados al proyecto

A medida que se fue profundizando en la documentación y se identificaron casos reales relevantes, fue necesario introducir varios ajustes metodológicos y operativos para mantener la robustez del estudio y su utilidad práctica. Primero, se ha refinado el criterio de selección de casos: en lugar de limitarse a ejemplos genéricos sobre IA, se priorizaron incidentes con evidencias públicas suficientes que permitieran analizar con cierto detalle la técnica usada, el vector de ataque y las consecuencias observadas. Este cambio reduce el riesgo de basar conclusiones en anécdotas o en informes incompletos, y permite una comparación más fiable entre casos.

En segundo lugar, dado que la literatura y los informes oficiales muestran una aceleración en el uso de herramientas generativas en ataques ([SlashNext, 2024](#)) (por ejemplo, para phishing y para creación de contenido sintético), se decidió

incorporar un proceso de verificación cruzada de fuentes más estricto. Es decir: cada caso incluido debe estar respaldado por al menos dos fuentes independientes (por ejemplo, un informe técnico y una noticia o un comunicado de seguridad). Esto se ha hecho porque, en muchos incidentes, las empresas no ofrecen detalles técnicos completos por motivos de confidencialidad, lo que obliga a contrastar antes de extraer conclusiones firmes

Un tercer ajuste importante ha sido introducir una categoría de “grado de evidencia” para cada caso analizado. No todos los incidentes presentan la misma calidad informativa: algunos están documentados con informes forenses, otros solo con comunicados de prensa; por tanto, cada caso ahora lleva una etiqueta que va desde “evidencia sólida” hasta “evidencia limitada”. Esta clasificación ayuda a matizar las interpretaciones y evita generalizaciones apresuradas. Además, permite al lector distinguir entre hallazgos bien confirmados y observaciones preliminares que necesitan más comprobación.

Otro ajuste metodológico se refiere al alcance temporal de las fuentes. Inicialmente se priorizaron textos de los últimos cinco años, pero al comprobar la velocidad de evolución del fenómeno se redujo ese umbral para los casos y reportes técnicos a los últimos tres años, y en muchos apartados incluso a los últimos dos. Esto asegura que los resultados iniciales sean relevantes frente a la realidad actual, donde herramientas y tácticas cambian en meses. No es una elección arbitraria: Europol y otros organismos recomiendan enfocar el análisis hacia fuentes recientes debido a la rápida aparición de nuevos vectores y técnicas ([Europol, 2024](#)) .

En cuanto a la posible incorporación de investigación primaria que el profesor ha sugerido reforzar en la segunda entrega se han diseñado ahora pasos preparatorios. En esta fase intermedia se ha descartado realizar experimentación práctica (p. ej. generación activa de malware o deepfakes) por motivos éticos y legales ([NIST, 2023](#)); en su lugar se plantea en la fase siguiente la realización de entrevistas semiestructuradas con profesionales del sector y la elaboración de un breve cuestionario dirigido a responsables de seguridad en empresas medianas y grandes. Estas actividades permitirán recoger datos cualitativos y contrastar las hipótesis surgidas del análisis documental, sin poner en riesgo la integridad del estudio ni violar normas éticas.

También se ha introducido un ajuste en la presentación de resultados: para cada caso real se incluirá ahora un pequeño esquema técnico (vector de ataque, herramienta IA implicada, efectos sobre la víctima, medidas de mitigación aplicadas) y un comentario interpretativo sobre la probabilidad de replicación a gran

escala. Esto facilita que el análisis no sea meramente narrativo, sino que muestre elementos replicables y comparables entre incidentes, y que permita identificar tendencias por ejemplo, si cierto tipo de deepfake o de phishing asistido por IA está repitiéndose con variaciones claras. La literatura reciente coincide en que estos patrones son cada vez más importantes para anticipar riesgos.

Finalmente, se ha revisado el equilibrio entre profundidad técnica y claridad expositiva. Muchos informes técnicos son densos y difíciles de sintetizar para una audiencia mixta; por ello, se ha decidido mantener un lenguaje técnico cuando sea necesario, pero acompañarlo de resúmenes ejecutivos y tablas que resuman las implicaciones principales para equipos de seguridad. Este compromiso busca que el proyecto sea útil tanto para un lector académico como para un profesional de ciberseguridad que necesite conclusiones prácticas y aplicables inmediatamente. En la práctica, esto ha supuesto rehacer algunos párrafos del AB1 y ajustar el nivel de detalle en la documentación de casos.

En resumen, los ajustes realizados tienen como objetivo mejorar la validez, fiabilidad y relevancia del estudio. No modifican la hipótesis central ni el enfoque general; más bien, afinan las herramientas metodológicas para que los resultados iniciales que se presentarán a continuación sean más robustos y mejor contextualizados. Estos cambios responden además a recomendaciones observadas en la bibliografía especializada y en los informes institucionales, que insisten en la necesidad de metodologías adaptativas frente a la rápida evolución de las amenazas basadas en IA.

6. Resultados Iniciales y Análisis de Casos

Tras completar la fase de recolección documental y aplicar los filtros de fiabilidad descritos en la metodología, el análisis de los datos arroja una primera conclusión contundente: la teoría sobre los riesgos de la IA generativa se ha materializado mucho más rápido de lo que las predicciones académicas de hace dos años anticipaban. Ya no estamos hablando de escenarios hipotéticos o pruebas de concepto en laboratorios de investigación; los resultados muestran que estas herramientas son ahora parte activa y cotidiana del arsenal ofensivo.

A continuación, se presentan los hallazgos divididos por vector de ataque, integrando estadísticas recientes y casos de estudio que demuestran el cambio cualitativo en las amenazas.

6.1. Ingeniería Social Automatizada: El salto de calidad y volumen en el Phishing

El hallazgo más significativo de esta investigación reside en la transformación del phishing. Históricamente, la defensa contra el phishing se basaba en identificar errores humanos en el atacante: mala gramática, formatos inconsistentes o traducciones automáticas de baja calidad. Sin embargo, los datos recopilados indican que esa "ventana de oportunidad" para la detección se ha cerrado.

Según el último informe sobre el estado del phishing de [SlashNext \(2024\)](#), se ha registrado un aumento vertiginoso del 4.151% en el volumen de correos maliciosos desde el lanzamiento de ChatGPT a finales de 2022. Este dato es revelador porque correlaciona directamente la disponibilidad de Modelos de Lenguaje Grande (LLMs) con la capacidad de disparo de los ciberdelincuentes. No es simplemente que haya más ataques, es que la IA ha eliminado el cuello de botella de la redacción manual.

Además, la calidad de estos ataques ha mejorado sustancialmente. El análisis de [Kaspersky \(2025\)](#) señala que sus sistemas bloquearon más de 893 millones de intentos de phishing durante el último periodo analizado, lo que representa un incremento del 26% respecto al año anterior. Lo preocupante no es solo el número, sino la sofisticación: los correos generados por IA ahora son capaces de imitar el tono corporativo, utilizar jerga específica de la industria y carecen de los errores ortográficos que antes servían de alerta temprana para los empleados.

Esto confirma que la IA generativa ha democratizado la capacidad de realizar spear-phishing (phishing dirigido). Anteriormente, personalizar un correo para un directivo requería horas de investigación y redacción cuidadosa. Hoy, herramientas derivadas de modelos abiertos permiten a un atacante generar cientos de variantes personalizadas en segundos, aumentando la tasa de éxito de forma exponencial.

6.2. Fraude Financiero mediante Deepfakes de Audio y Video

Si el phishing representa el ataque por volumen, los deepfakes representan el ataque de alto impacto. Durante la revisión de casos, se ha identificado un incidente que marca un antes y un después en la ciberseguridad corporativa: el caso de la firma multinacional Arup.

Tal y como reporta [Check Point Research \(2024\)](#), un empleado del departamento financiero de esta compañía fue engañado para realizar transferencias por valor de 25 millones de dólares tras asistir a una videollamada. Lo aterrador de este caso es que todos los participantes en la llamada, excepto la víctima, eran recreaciones deepfake generadas por IA que imitaban la apariencia y la voz del director financiero y otros colegas. Este nivel de engaño, que supera cualquier barrera de

concienciación tradicional, demuestra que la verificación visual ya no es garantía de identidad.

Pero el video no es el único riesgo. Los datos sugieren que el audio es una amenaza aún más insidiosa y extendida. Un análisis citado por Check Point indica que el fraude mediante voz sintética aumentó un 173% en el último año. La tecnología actual permite clonar la voz de una persona con apenas unos segundos de audio de referencia, que a menudo se extraen de redes sociales o vídeos corporativos públicos. Esto pone en jaque los sistemas de autenticación biométrica por voz que muchos bancos habían empezado a implementar, obligando a repensar los protocolos de seguridad telefónica desde cero.

6.3. Desarrollo de Malware y la reducción de barreras técnicas

Finalmente, en el ámbito del software malicioso, los resultados muestran una tendencia clara hacia la asistencia técnica. Aunque todavía no se ha detectado un malware "autónomo" que se reescriba a sí mismo en tiempo real de forma perfecta, la IA está actuando como un copiloto eficaz para los desarrolladores de malware.

Los sistemas de detección de [Kaspersky \(2025\)](#) identificaron una media de 467.000 nuevos archivos maliciosos cada día durante el último año, un aumento del 14% frente al periodo anterior. Este incremento sugiere que la IA está ayudando a los atacantes a generar variaciones de código con mayor rapidez, permitiéndoles eludir las firmas de los antivirus tradicionales mediante técnicas de ofuscación automatizada.

[Europol \(2024\)](#), en su evaluación de amenazas (IOCTA), advierte que esta tendencia continuará. La IA permite a actores con pocos conocimientos técnicos escribir scripts funcionales o mejorar código defectuoso, bajando la barrera de entrada al cibercrimen. Ya no hace falta ser un experto en C++ o ensamblador para lanzar una campaña de malware efectiva; basta con saber preguntar al modelo de IA adecuado.

7. Discusión: Interpretación de los hallazgos y contraste teórico

Una vez expuestos los datos y los casos recientes, es necesario detenerse a interpretar qué significan realmente para el panorama de la ciberseguridad actual. Si retomamos la pregunta de investigación planteada al inicio de este proyecto *¿Cómo están usando los atacantes la IA generativa y qué impacto futuro tiene?* la

respuesta que emerge del análisis es bastante más compleja y alarmante de lo que sugería la teoría inicial.

A continuación, discuto las cuatro implicaciones críticas que se derivan de los resultados obtenidos y que redefinen nuestra comprensión del problema.

7.1. La paradoja de la "Democratización del Cibercrimen"

En la revisión de literatura (sección 2.2.3), citamos estudios teóricos que advertían sobre cómo la IA podría ayudar a crear malware. Sin embargo, los resultados del análisis de amenazas de 2024 ([Kaspersky](#), [Europol](#)) confirman que esto ya no es una advertencia futura, sino una realidad operativa.

Lo que estamos viendo es una reducción drástica de la barrera de entrada. Tradicionalmente, ser un ciberdelincuente peligroso requería años de aprendizaje técnico profundo. Hoy, los hallazgos sugieren que herramientas como ChatGPT (o sus versiones sin censura en la Dark Web, como WormGPT) actúan como "mentores" instantáneos. Esto crea una asimetría peligrosa: mientras que los equipos defensivos necesitan formación constante y costosa, los atacantes pueden suplir su falta de habilidades con asistencia sintética.

Esto cambia radicalmente el perfil de riesgo para las empresas: ya no solo deben preocuparse por los grupos de hackers de élite (APTs), sino por una masa creciente de atacantes de bajo nivel que ahora poseen capacidades ofensivas de nivel medio gracias a la IA.

7.2. El fin de la concienciación tradicional

Quizás el punto más crítico de esta discusión es que los datos sobre phishing y deepfakes nos obligan a admitir que las estrategias clásicas de formación de empleados están quedándose obsoletas.

Durante años, la industria ha enseñado a los usuarios a buscar "señales de alerta": faltas de ortografía, saludos genéricos o vídeos con movimientos extraños. Pero, como vimos en el caso de Arup y en las estadísticas de [SlashNext](#), la IA generativa ha eliminado precisamente esas señales. Si un correo de phishing es gramaticalmente perfecto y un audio clonado suena idéntico al del CEO, ¿cómo podemos exigirle al empleado que lo detecte?

La interpretación de estos hallazgos sugiere que la responsabilidad de la detección debe trasladarse progresivamente del humano a la tecnología. No es viable culpar a una persona por caer en un engaño que es técnicamente indistinguible de la realidad.

7.3. Velocidad vs. Precisión: La nueva carrera armamentística

Al contrastar los resultados actuales con la literatura del AB1, se observa una discrepancia significativa en los tiempos. Los artículos académicos de 2022-2023 hablaban de estos riesgos como algo a medio plazo, pero la realidad de 2024/2025 muestra que la adopción ha sido inmediata.

El análisis de tendencias indica que los atacantes tienen una ventaja estructural: la agilidad. Mientras una empresa tarda meses en aprobar presupuestos e implementar un nuevo sistema de defensa, un ciberdelincuente puede adoptar una nueva herramienta generativa en una tarde. Esta brecha de velocidad es lo que está permitiendo el aumento masivo en las tasas de éxito de los ataques de ingeniería social que hemos documentado anteriormente.

7.4. Hacia un cambio de paradigma defensivo

Finalmente, la evidencia recopilada apunta a una conclusión inevitable: las herramientas defensivas actuales no están diseñadas para este nuevo tipo de amenaza. Los antivirus tradicionales buscan firmas de código conocidas, pero la IA genera código polimórfico que cambia constantemente. Los protocolos de verificación de voz asumen que la voz es única, pero la IA ha roto esa asunción.

Por lo tanto, la discusión no puede quedarse en el diagnóstico. La gravedad de los hallazgos hace evidente que el mero análisis de los ataques es insuficiente si no va acompañado de una propuesta de mitigación adaptada. Esto justifica la necesidad de formular, en la siguiente sección de este trabajo, un conjunto de estrategias de defensa (técnicas y procedimentales) que superen el enfoque reactivo tradicional y abracen modelos como Zero Trust ([IBM 2024](#)). Ya no se trata de preguntar "si" nos atacarán con IA, sino de rediseñar nuestros protocolos asumiendo que ya lo están haciendo.

8. Conclusiones Preliminares de la Fase Intermedia

Al llegar a este punto intermedio del proyecto, y retomando la pregunta de investigación sobre el uso ofensivo de la IA generativa, el análisis realizado permite extraer varias conclusiones provisionales que guiarán las siguientes etapas del trabajo.

En primer lugar, la evidencia recopilada hasta la fecha sugiere que la democratización de la sofisticación es un hecho consumado. Los datos analizados en esta fase muestran que la barrera técnica para ejecutar ataques complejos (como *phishing* contextualizado) ha desaparecido prácticamente. Lo que al inicio del estudio se planteaba como una hipótesis teórica, se ha confirmado mediante los reportes de incidentes de 2024: la calidad de los ataques masivos ha aumentado drásticamente gracias a la asistencia de LLMs.

En segundo lugar, se observa una brecha crítica en la defensa. Mientras que las herramientas ofensivas evolucionan a ritmo semanal, las estrategias defensivas que hemos revisado parecen ir un paso por detrás, dependiendo todavía en exceso del factor humano. Esto refuerza la necesidad de profundizar, en las próximas entregas, en la viabilidad técnica de las soluciones *Zero Trust* que hemos esbozado en la propuesta de mitigación.

Por último, se concluye provisionalmente que el impacto futuro no dependerá tanto de la tecnología en sí, sino de la velocidad de adopción. La ventaja actual de los atacantes reside en su agilidad; por tanto, el resto de la investigación deberá centrarse en cómo las organizaciones pueden automatizar sus respuestas para cerrar esa ventana de tiempo.

9. Revisión del Progreso y Planificación Futura

Para cerrar esta segunda entrega (AB2), es necesario evaluar el estado actual del proyecto y definir la hoja de ruta para las fases finales (AB3 y Entrega Final).

Evaluación del trabajo realizado La metodología de análisis documental ha demostrado ser efectiva para construir una base sólida de conocimiento sobre las amenazas actuales. La decisión de descartar la experimentación práctica por motivos éticos y centrarse en el análisis de casos reales ha permitido avanzar sin riesgos legales, obteniendo resultados que son coherentes con la literatura más reciente. Se ha logrado cumplir con los objetivos específicos de identificar vectores de ataque y proponer contramedidas iniciales.

Ajustes para las siguientes fases Sin embargo, el trabajo presenta áreas que requieren mayor desarrollo en las próximas entregas. Ahora que se han identificado las estrategias de mitigación (Defensa tecnológica y *Zero Trust*), el objetivo para la siguiente fase será detallar **cómo** se pueden implementar estas soluciones de manera realista en diferentes tipos de organizaciones, analizando sus costes y barreras de entrada.

Próximos pasos De cara al tercer entregable y a la finalización del proyecto, el trabajo se centrará en:

- Refinar la propuesta de mitigación, contrastándola con marcos de trabajo estándar (como NIST o ISO) para darle mayor validez profesional.

- Ampliar la discusión sobre las implicaciones éticas y legales del uso de IA defensiva, un aspecto que solo se ha tocado superficialmente en esta fase.
- Sintetizar todos los hallazgos para elaborar un conjunto final de recomendaciones que responda de manera integral a la pregunta de investigación.

De esta forma, el proyecto se mantiene en curso, con una base teórica y práctica ya establecida, y con una dirección clara para lograr una conclusión robusta en la entrega final.

10. Investigación primaria y validación cualitativa

Hasta este punto, gran parte del proyecto se había apoyado en análisis documental, informes técnicos y estudios publicados por empresas y organismos especializados. Eso permitió construir una base bastante sólida sobre cómo la IA generativa está cambiando el panorama de la ciberseguridad. Aun así, mientras avanzaba la investigación apareció una idea bastante clara: hacía falta incorporar aunque fuera una pequeña parte de investigación primaria para comprobar si todo lo que muestran los informes también se refleja en la percepción real de las personas.

Y honestamente, ahí es donde el proyecto empezó a sentirse más “vivo”. Una cosa es leer estadísticas de Europol o Kaspersky, y otra distinta es ver cómo usuarios reales reaccionan cuando se les habla de phishing generado por IA, clonación de voz o deepfakes corporativos.

Por ese motivo, se decidió incorporar una fase cualitativa sencilla, basada en un cuestionario exploratorio y varias entrevistas semiestructuradas. El objetivo no era realizar un estudio estadístico masivo ni obtener resultados universales. La intención era más práctica: identificar tendencias, percepciones comunes y posibles diferencias entre perfiles con distintos niveles de conocimientos tecnológicos.

La muestra estuvo formada por quince participantes divididos en tres grupos principales. Por un lado, estudiantes de informática y ciberseguridad. También participaron usuarios con cierta experiencia tecnológica en entornos corporativos, aunque sin especialización directa en seguridad. Finalmente, se incluyeron usuarios generales, con un conocimiento mucho más básico sobre amenazas digitales.

La diferencia entre perfiles resultó bastante interesante desde el principio. Los participantes con conocimientos técnicos mostraban preocupación especialmente por la velocidad a la que evolucionan estas herramientas. En cambio, muchos usuarios no técnicos seguían asociando el phishing a señales tradicionales como errores ortográficos o mensajes mal redactados, algo que precisamente contradice

las tendencias observadas en informes recientes de SlashNext (2024) y [Microsoft \(2024\)](#).

El cuestionario se estructuró alrededor de varias áreas concretas. Primero, la capacidad percibida para detectar phishing generado mediante IA. Después, el nivel de confianza en mecanismos tradicionales de verificación, como llamadas telefónicas, correos corporativos o reconocimiento de voz. También se analizaron aspectos relacionados con deepfakes, preparación empresarial frente a amenazas basadas en IA y conocimiento previo sobre este tipo de ataques.

Las entrevistas ayudaron a complementar esos datos con respuestas más abiertas. Y sinceramente, algunas reflejaban bastante bien el cambio de percepción que está ocurriendo actualmente en ciberseguridad. Un participante relacionado con administración de sistemas comentaba que hace unos años todavía se confiaba mucho en la “intuición” de los empleados para detectar fraudes, pero que ahora esa estrategia empieza a quedarse corta porque los ataques son mucho más convincentes. Otro participante mencionó que la posibilidad de clonar voces o generar videollamadas falsas le parecía mucho más preocupante que el malware tradicional, precisamente porque explota directamente la confianza humana.

Metodológicamente, esta fase mantiene un enfoque claramente exploratorio. No busca reemplazar la revisión documental desarrollada anteriormente, sino complementarla. De hecho, la idea principal era comprobar si las preocupaciones y tendencias identificadas en la literatura reciente aparecían también a pequeña escala en usuarios reales. Y, en líneas generales, sí ocurrió.

Además, incorporar esta parte cualitativa aporta algo que el proyecto todavía no tenía del todo: una dimensión más humana. Porque al final muchas de las amenazas impulsadas por IA generativa no atacan únicamente sistemas técnicos; atacan percepción, identidad y confianza. Y eso cambia bastante el enfoque tradicional de la ciberseguridad.

Obviamente, esta aproximación también tiene limitaciones. La muestra es reducida y no permite extraer conclusiones universales. Además, algunos participantes tenían un nivel de conocimiento técnico superior al promedio, lo que puede influir en ciertas respuestas. Aun así, los resultados obtenidos siguen siendo útiles como validación cualitativa preliminar y ayudan a reforzar varias de las tendencias detectadas previamente en informes institucionales y estudios académicos recientes.

11. Resultados avanzados y contraste con la literatura

Una vez recopiladas las respuestas del cuestionario y revisadas las entrevistas realizadas, comenzaron a aparecer varios patrones bastante consistentes. Algunos ya se intuían en la literatura revisada durante el AB2, pero verlos reflejados

directamente en las respuestas de los participantes hizo que el impacto resultara mucho más evidente.

El primer resultado relevante tiene relación con el phishing generado mediante IA. Aproximadamente un 73% de los participantes afirmó que actualmente le resultaría más difícil distinguir un correo fraudulento si estuviese redactado utilizando herramientas generativas avanzadas. Lo interesante es que esta percepción aparecía incluso entre perfiles técnicos. No se trataba únicamente de usuarios sin experiencia. De hecho, varios estudiantes de informática señalaron que los ataques actuales ya no dependen tanto de errores evidentes, sino de pequeños detalles contextuales que muchas veces pasan desapercibidos cuando el mensaje parece legítimo.

Este resultado coincide bastante con las tendencias descritas por SlashNext (2024), donde se documenta un aumento masivo en campañas de phishing asistidas por IA y una mejora significativa en la calidad lingüística y contextual de los mensajes. [La diferencia respecto al phishing tradicional ya no es solo cuestión de volumen; es una cuestión de credibilidad.](#)

Otro aspecto que llamó bastante la atención fue la pérdida progresiva de confianza en sistemas clásicos de verificación. Un 66% de los participantes afirmó que confiaría menos en llamadas telefónicas, audios o videollamadas si supiera que podrían existir herramientas capaces de clonar voces o generar deepfakes en tiempo real. Honestamente, este punto refleja bastante bien el cambio de paradigma que está ocurriendo ahora mismo.

Hace apenas unos años, escuchar la voz de un directivo o verlo en una videollamada podía considerarse una prueba de autenticidad relativamente sólida. Ahora esa percepción empieza a romperse. Y eso es preocupante, porque [muchas empresas todavía siguen utilizando métodos de validación basados precisamente en elementos que la IA generativa puede replicar con bastante eficacia.](#)

Las entrevistas reforzaron todavía más esta idea. Un participante relacionado con soporte técnico comentaba que el problema ya no es únicamente tecnológico, sino psicológico. Según su percepción, las personas tienden a confiar automáticamente en aquello que “parece real”, incluso cuando conocen la existencia de deepfakes o herramientas de clonación de voz. Esa contradicción apareció varias veces durante las entrevistas y probablemente sea uno de los elementos más peligrosos de este nuevo escenario.

También surgieron diferencias interesantes entre perfiles técnicos y no técnicos. Los usuarios con conocimientos de ciberseguridad mostraban una preocupación mucho mayor por ataques automatizados y escalables, especialmente phishing personalizado o generación masiva de identidades falsas. En cambio, muchos usuarios generales seguían asociando el mayor riesgo a malware tradicional o robo directo de contraseñas.

Eso sugiere algo importante: la percepción pública de las amenazas todavía parece ir un paso por detrás de la evolución real del problema. Y, sinceramente, no es difícil entender por qué. La velocidad con la que avanzan estas herramientas es enorme. Modelos capaces de generar texto convincente, imágenes realistas o audio sintético aparecen prácticamente cada pocos meses, mientras que la formación en ciberseguridad dentro de muchas organizaciones sigue anclada en amenazas mucho más tradicionales.

Otro dato interesante fue que solo un 20% de los participantes consideró que las empresas están realmente preparadas para afrontar amenazas basadas en IA generativa. La mayoría describió las medidas actuales como “insuficientes” o “todavía demasiado reactivas”. Esto coincide bastante con los informes de IBM Security (2024) y Europol (2024), donde se insiste en que gran parte de las organizaciones continúan dependiendo de modelos defensivos pensados para amenazas estáticas, no para ataques adaptativos generados dinámicamente mediante IA.

Además, varios participantes señalaron algo que apareció repetidamente durante todo el análisis: la sensación de que la tecnología ofensiva está evolucionando más rápido que la capacidad defensiva de las organizaciones. Y, aunque pueda sonar exagerado, los datos revisados durante el proyecto apuntan precisamente hacia esa dirección.

No obstante, tampoco todas las respuestas fueron pesimistas. Algunos perfiles técnicos destacaron que la propia IA también puede convertirse en una herramienta defensiva potente, especialmente en detección conductual, análisis automatizado de anomalías y respuesta temprana frente a campañas masivas. Esta visión encaja con varias propuestas recientes relacionadas con IA defensiva y arquitecturas Zero Trust, que empiezan a aparecer cada vez más en informes corporativos y marcos de seguridad modernos.

En conjunto, los resultados obtenidos durante esta fase cualitativa no contradicen la literatura revisada anteriormente. Más bien la refuerzan. Las preocupaciones observadas en informes institucionales, artículos técnicos y análisis académicos aparecen también, aunque a menor escala, en la percepción de usuarios reales. Y eso probablemente sea uno de los hallazgos más importantes de esta parte del proyecto: las amenazas basadas en IA generativa ya no se perciben como algo futurista o lejano. Poco a poco empiezan a entenderse como un problema actual, cercano y mucho más difícil de identificar utilizando estrategias tradicionales.

12. Estrategias de mitigación y adaptación defensiva

12.1. La necesidad de cambiar el enfoque defensivo

Después de analizar tanto los casos reales como los resultados obtenidos en la fase cualitativa, aparece una idea bastante clara: muchas estrategias defensivas tradicionales empiezan a quedarse cortas frente a amenazas impulsadas por IA generativa. No porque hayan dejado de funcionar completamente, sino porque fueron diseñadas para un escenario mucho más predecible que el actual.

Durante años, gran parte de la ciberseguridad corporativa se apoyó en mecanismos relativamente estables. Los sistemas defensivos buscaban patrones conocidos, los empleados aprendían a identificar señales típicas de phishing y las verificaciones de identidad dependían de elementos que, en teoría, eran difíciles de falsificar. El problema es que la IA generativa está erosionando precisamente esas referencias tradicionales.

Ahora un atacante puede generar correos perfectamente redactados, clonar voces con pocos segundos de audio o crear identidades falsas bastante convincentes sin necesidad de grandes conocimientos técnicos. Y eso cambia muchísimo el panorama. De hecho, varios participantes del cuestionario comentaron algo parecido: sienten que cada vez resulta más complicado confiar en elementos que antes parecían relativamente seguros.

La consecuencia directa es que muchas organizaciones están empezando a replantearse cómo entienden la autenticación, la confianza digital y la detección de amenazas. Ya no basta únicamente con bloquear malware conocido o enseñar a los empleados a desconfiar de mensajes mal escritos. El entorno se ha vuelto mucho más dinámico.

12.2. Zero Trust y autenticación reforzada

Dentro de las estrategias más repetidas en informes recientes aparece el modelo [Zero Trust](#). Aunque el concepto no es nuevo, la expansión de amenazas basadas en IA lo ha vuelto especialmente relevante. La idea principal consiste en no asumir automáticamente que un usuario o dispositivo es legítimo solo porque ya haya superado una validación inicial.

Esto cobra sentido en un contexto donde herramientas generativas pueden replicar identidades digitales de manera bastante convincente. Un correo corporativo, una llamada telefónica o incluso una videollamada ya no pueden considerarse pruebas totalmente fiables por sí solas.

Por ese motivo, muchas empresas están evolucionando hacia sistemas de verificación continua y autenticación multinivel. IBM Security (2024) y Microsoft (2024) coinciden en que el futuro de la seguridad corporativa dependerá cada vez más de modelos capaces de analizar contexto y comportamiento, no únicamente credenciales estáticas.

En este punto también entra en juego la autenticación multifactor. Aunque actualmente está muy extendida, no todos los métodos ofrecen la misma protección frente a amenazas modernas. Algunos sistemas siguen dependiendo de SMS o validaciones telefónicas relativamente vulnerables a ingeniería social avanzada.

En cambio, tecnologías como FIDO2 o autenticación basada en hardware físico muestran una resistencia mucho mayor frente a phishing automatizado o robo de credenciales ([Google Cloud, 2023](#)). Aun así, implementar este tipo de soluciones no siempre resulta sencillo, especialmente en organizaciones medianas que todavía priorizan facilidad de uso o reducción de costes.

Y sinceramente, ahí aparece uno de los grandes conflictos actuales de la ciberseguridad: encontrar equilibrio entre seguridad fuerte y experiencia de usuario razonable.

12.3. IA defensiva y detección conductual

Curiosamente, parte de la solución probablemente dependa también de inteligencia artificial. A medida que los ataques se vuelven más adaptativos, las defensas necesitan desarrollar cierta capacidad de respuesta dinámica.

En lugar de limitarse a buscar firmas conocidas o patrones estáticos, muchos sistemas modernos empiezan a centrarse en comportamiento. Es decir, intentan detectar anomalías aunque el ataque concreto nunca haya sido visto anteriormente.

Por ejemplo:

- accesos desde ubicaciones inusuales,
- movimientos extraños dentro de redes corporativas,
- patrones de actividad atípicos,
- comportamientos inconsistentes respecto al uso habitual de una cuenta.

Este enfoque resulta especialmente útil frente a campañas generadas mediante IA, donde cada variante puede ser ligeramente distinta a la anterior. Y eso dificulta bastante la detección tradicional basada únicamente en coincidencias exactas.

Sin embargo, tampoco conviene idealizar estas herramientas. Algunos informes recientes advierten de que los sistemas defensivos basados en IA todavía generan bastantes falsos positivos y requieren supervisión humana constante. Además, los atacantes también evolucionan rápidamente. De hecho, gran parte del problema actual parece una carrera continua entre adaptación ofensiva y adaptación defensiva.

12.4. Formación y adaptación humana

Más allá de la tecnología, hubo un aspecto que apareció repetidamente tanto en entrevistas como en literatura especializada: muchas estrategias de formación siguen enfocadas en amenazas demasiado antiguas.

Durante años, la concienciación en ciberseguridad se basó en enseñar a detectar señales relativamente simples:

- faltas de ortografía,
- enlaces sospechosos,
- mensajes genéricos,
- formatos extraños.

El problema es que gran parte de esas señales empiezan a desaparecer cuando los ataques son generados mediante modelos lingüísticos avanzados.

Varios participantes reconocieron que nunca habían recibido formación específica relacionada con deepfakes, clonación de voz o manipulación audiovisual generada por IA. Y eso resulta preocupante porque muchas amenazas actuales ya no atacan únicamente sistemas técnicos; atacan percepción, confianza y comportamiento humano.

Por ese motivo, algunos expertos empiezan a defender modelos de formación mucho más dinámicos, basados en simulaciones reales y escenarios adaptativos. No basta con enseñar a “no abrir enlaces sospechosos”. Ahora también es necesario enseñar a verificar identidades, desconfiar de validaciones puramente visuales o comprender cómo funciona la manipulación generativa.

En conjunto, todo apunta a que la defensa frente a amenazas basadas en IA generativa dependerá menos de una herramienta concreta y más de la capacidad de adaptación continua de las organizaciones. Y probablemente esa sea una de las conclusiones más importantes de esta fase del proyecto.

13. Planificación de la comunicación y difusión de resultados

Una vez completada la fase principal de análisis e interpretación, también resulta importante plantear cómo deberían comunicarse los resultados obtenidos. Y sinceramente, esto tiene bastante más importancia de lo que puede parecer al principio. En un tema tan dinámico como la IA generativa aplicada a ciberseguridad, no basta únicamente con investigar amenazas; también es necesario conseguir que la información llegue de forma clara a los perfiles que realmente pueden verse afectados.

Además, uno de los problemas detectados durante todo el proyecto es precisamente [la diferencia entre el ritmo al que evolucionan las amenazas y el nivel de conocimiento que existe fuera de entornos especializados](#). Mientras organismos como Europol, Microsoft o IBM Security publican informes cada vez más avanzados, muchas empresas y usuarios siguen asociando la ciberseguridad a amenazas bastante tradicionales.

Por ese motivo, la comunicación de resultados debe adaptarse al público objetivo y no limitarse únicamente al formato académico.

13.1. Comunicación en entornos académicos y técnicos

En primer lugar, parte de los resultados del proyecto están claramente orientados a un contexto académico y profesional. La revisión documental, el análisis de tendencias y la incorporación de investigación cualitativa permiten construir una visión relativamente completa sobre cómo la IA generativa está transformando ciertos modelos de ataque.

En este tipo de contextos, la comunicación debe priorizar claridad metodológica, referencias verificables y capacidad crítica. No basta solo con mostrar datos; también es necesario explicar cómo se interpretan y cuáles son sus limitaciones.

Por ello, una parte importante de la difusión estaría basada en:

- informes estructurados,
- presentaciones técnicas,
- tablas comparativas,
- análisis apoyados en bibliografía reciente.

Especialmente en ciberseguridad, donde muchas veces aparecen afirmaciones exageradas o poco contrastadas, mantener una base documental sólida resulta fundamental para conservar credibilidad.

13.2. Comunicación hacia empresas y usuarios no especializados

Sin embargo, limitar la comunicación únicamente al ámbito técnico sería insuficiente. Gran parte de las amenazas analizadas durante este proyecto dependen precisamente de explotar desconocimiento, confianza o percepción humana. Y eso significa que usuarios generales y empresas no especializadas también necesitan comprender el problema.

Aquí el enfoque cambia bastante. Un informe académico de veinte páginas probablemente no resulte útil para un empleado administrativo o para una pequeña empresa sin departamento de ciberseguridad. En esos casos, la comunicación necesita ser mucho más directa, visual y práctica.

Por ejemplo, durante la investigación aparecieron varias ideas que podrían transformarse fácilmente en material de concienciación:

- ejemplos reales de phishing generado por IA,
- riesgos asociados a clonación de voz,
- situaciones donde un deepfake puede utilizarse para fraude corporativo.

La clave estaría en explicar estos riesgos sin caer en alarmismo innecesario. Porque otro problema bastante habitual en temas relacionados con IA es que muchas veces la comunicación pública oscila entre dos extremos: o se minimiza el problema o se presenta casi como una amenaza imposible de detener. Y ninguna de las dos perspectivas ayuda realmente.

13.3. Uso de formatos visuales y divulgativos

Otro aspecto importante es el formato. A lo largo del proyecto quedó claro que muchos conceptos relacionados con IA generativa pueden resultar abstractos o difíciles de visualizar para usuarios no técnicos. Por ese motivo, algunos formatos probablemente serían mucho más eficaces que un texto académico tradicional.

Infografías, pequeños esquemas visuales o comparativas simples podrían ayudar bastante a transmitir ciertas ideas clave. Por ejemplo, explicar visualmente cómo evoluciona un ataque de phishing tradicional frente a uno generado mediante IA resulta mucho más intuitivo que limitarse a describirlo únicamente con teoría.

Además, plataformas digitales y redes profesionales también juegan un papel importante en este contexto. Gran parte de la información sobre amenazas emergentes se mueve actualmente a enorme velocidad, y muchas veces los equipos de seguridad necesitan respuestas rápidas más que documentos excesivamente largos.

Aun así, existe un riesgo evidente: simplificar demasiado puede hacer que se pierda precisión técnica. Por eso la comunicación debe encontrar cierto equilibrio entre accesibilidad y rigor.

13.4. Importancia de la concienciación continua

Probablemente una de las conclusiones más importantes de esta parte del proyecto es que la comunicación en ciberseguridad ya no puede entenderse como algo puntual. No basta con realizar una formación anual o enviar recomendaciones aisladas después de un incidente.

Las amenazas basadas en IA evolucionan demasiado rápido para eso.

De hecho, varios participantes de la investigación cualitativa comentaron que gran parte de la información que reciben sobre seguridad sigue centrada en amenazas relativamente antiguas. Mientras tanto, tecnologías capaces de generar audio sintético, imágenes hiperrealistas o mensajes personalizados continúan avanzando prácticamente cada pocos meses.

Eso obliga a replantear también la forma de comunicar riesgo digital. La concienciación tendrá que ser mucho más continua, flexible y adaptativa, igual que las propias amenazas.

Y sinceramente, ahí probablemente se encuentra uno de los mayores desafíos futuros: no solo desarrollar mejores herramientas defensivas, sino conseguir que personas y organizaciones entiendan realmente cómo está cambiando el panorama de la ciberseguridad antes de que los ataques evolucionen todavía más rápido.

14. Conclusiones

Al llegar al final de esta investigación, la principal conclusión que emerge es que la inteligencia artificial generativa ya no puede entenderse como una amenaza futura o meramente experimental dentro de la ciberseguridad. A lo largo del proyecto, tanto la revisión documental como el análisis de casos reales y la pequeña fase de investigación cualitativa apuntan hacia la misma dirección: estas tecnologías ya forman parte activa del panorama ofensivo actual.

Y sinceramente, probablemente esa sea una de las ideas más importantes de todo el trabajo. La velocidad con la que se ha producido esta transición ha sido muchísimo mayor de lo que gran parte de la literatura inicial preveía.

Cuando comenzó la expansión pública de herramientas generativas como ChatGPT, muchos análisis todavía trataban el uso ofensivo de IA como un escenario potencial a medio plazo. Sin embargo, los casos revisados durante la

investigación muestran que ataques relacionados con phishing automatizado, deepfakes corporativos o generación asistida de malware ya están ocurriendo de manera real y sostenida. Europol (2024), Kaspersky (2025) y SlashNext (2024) coinciden precisamente en esa aceleración.

Otro aspecto importante es que el impacto de la IA generativa no depende únicamente de capacidades técnicas más avanzadas. En realidad, gran parte del cambio está relacionado con accesibilidad y escalabilidad. Herramientas que antes requerían conocimientos relativamente complejos ahora pueden utilizarse mediante instrucciones simples o plataformas fácilmente accesibles.

Eso modifica bastante el perfil tradicional del atacante. La investigación sugiere que la IA no necesariamente reemplaza a ciberdelincuentes expertos, pero sí reduce enormemente la barrera de entrada para actores con menor experiencia técnica. Y esa “democratización” de capacidades ofensivas apareció repetidamente tanto en literatura especializada como en la interpretación de resultados obtenidos durante el proyecto.

Además, el análisis realizado muestra algo especialmente preocupante: muchas estrategias defensivas continúan dependiendo demasiado de elementos humanos fácilmente manipulables. Durante años se enseñó a los usuarios a detectar señales evidentes de fraude digital, pero la IA generativa está eliminando precisamente esas señales. Un correo perfectamente redactado, una voz clonada o una videollamada falsa generan un escenario completamente distinto al que existía hace solo unos años.

Por ese motivo, varias de las conclusiones obtenidas apuntan hacia la necesidad de un cambio de paradigma defensivo. Modelos como Zero Trust, autenticación multifactor resistente a phishing o detección conductual basada en IA empiezan a aparecer no como mejoras opcionales, sino como adaptaciones necesarias frente a amenazas cada vez más dinámicas.

Aun así, el proyecto también permitió observar ciertas limitaciones importantes. No todas las organizaciones tienen recursos suficientes para implementar medidas avanzadas de defensa. Mientras grandes compañías tecnológicas pueden adoptar sistemas adaptativos relativamente rápido, muchas empresas medianas todavía presentan dificultades incluso para mantener políticas básicas de seguridad. Esto genera una situación desigual donde la evolución ofensiva avanza más rápido que la capacidad defensiva de una parte importante del tejido empresarial.

La fase de investigación cualitativa reforzó todavía más varias de estas conclusiones. Aunque la muestra utilizada fue reducida, los resultados mostraron una percepción creciente de incertidumbre frente a amenazas relacionadas con IA generativa. Muchos participantes reconocieron confiar menos en mecanismos tradicionales de validación y consideraron que las empresas todavía no están suficientemente preparadas para afrontar este tipo de ataques.

Y honestamente, esa percepción probablemente refleja bastante bien la situación actual. Existe una sensación clara de transición. La ciberseguridad está entrando en una etapa donde ya no basta únicamente con proteger sistemas técnicos; ahora también es necesario proteger percepción, identidad y confianza digital.

En conjunto, la investigación permite responder a la pregunta planteada al inicio del proyecto: los atacantes están utilizando IA generativa para automatizar, escalar y perfeccionar múltiples formas de ciberataque, especialmente aquellas relacionadas con ingeniería social y manipulación de identidad. El impacto futuro de estas amenazas dependerá, en gran medida, de la capacidad de adaptación de empresas, usuarios y sistemas defensivos frente a una tecnología que continúa evolucionando a enorme velocidad.

Y probablemente ahí reside la conclusión más relevante de todo el proyecto. El problema ya no es si la IA generativa cambiará la ciberseguridad. La realidad es que ya lo está haciendo.

15. Futuras líneas de investigación

Aunque esta investigación ha permitido identificar varias tendencias importantes relacionadas con el uso ofensivo de la IA generativa, el tema sigue evolucionando a una velocidad enorme. De hecho, probablemente una de las mayores dificultades del proyecto ha sido precisamente esa: mientras se analizaban determinados riesgos, aparecían nuevas herramientas, modelos y escenarios que modificaban parcialmente el panorama estudiado.

Por ese motivo, muchas de las conclusiones obtenidas aquí deben entenderse como una fotografía de un contexto todavía en transformación.

Una de las líneas futuras más relevantes tiene relación con los llamados agentes autónomos basados en IA. Actualmente, gran parte de los ataques generativos siguen dependiendo de intervención humana en algún punto del proceso. Sin embargo, algunos investigadores ya advierten sobre sistemas capaces de automatizar de manera mucho más completa tareas ofensivas como reconocimiento de objetivos, generación de phishing personalizado o adaptación dinámica frente a defensas detectadas.

Si estas capacidades continúan avanzando, el impacto podría ser considerable. No solo aumentaría el volumen de ataques, sino también su capacidad de adaptación en tiempo real.

Otro ámbito que probablemente requerirá mucha más investigación es el relacionado con IA multimodal. Hasta ahora, gran parte del análisis se ha centrado en texto, voz o imágenes de forma relativamente separada. Sin embargo, los modelos actuales empiezan a combinar varios formatos simultáneamente. Esto significa que futuros ataques podrían integrar:

- voz sintética,
- vídeo generado,
- interacción textual,
- incluso comportamiento automatizado coordinado dentro de un mismo escenario.

Y sinceramente, eso podría hacer que ciertos mecanismos tradicionales de validación pierdan todavía más eficacia.

También existe una necesidad evidente de investigar mejor cómo proteger infraestructuras críticas frente a amenazas basadas en IA generativa. Durante la revisión documental apareció repetidamente la preocupación sobre posibles ataques dirigidos a sectores como:

- energía,
- transporte,
- sanidad,
- sistemas financieros.

Aunque todavía existen pocos casos públicos suficientemente documentados, varios organismos internacionales consideran que este tipo de escenarios representa uno de los principales riesgos a medio plazo (Europol, 2024).

Otra línea especialmente interesante está relacionada con [detección de deepfakes en tiempo real](#). Actualmente ya existen herramientas capaces de identificar ciertas manipulaciones audiovisuales, pero la evolución de los modelos generativos está reduciendo progresivamente la eficacia de muchos sistemas de detección.

Esto genera una situación bastante complicada: a medida que mejora la generación sintética, las diferencias entre contenido real y contenido artificial se vuelven cada vez más difíciles de identificar incluso para sistemas automatizados.

Además, la investigación futura probablemente también tendrá que centrarse más en factores humanos y psicológicos. A lo largo de este proyecto quedó bastante claro que muchas amenazas modernas no dependen únicamente de vulnerabilidades técnicas, sino de confianza, percepción y comportamiento humano.

Por eso sería interesante desarrollar estudios más amplios sobre:

- fatiga de verificación,
- percepción de autenticidad digital,

- confianza en sistemas biométricos,
- impacto psicológico de deepfakes y manipulación sintética.

En paralelo, otro aspecto que seguirá ganando importancia es el ámbito legal y regulatorio. La velocidad de evolución tecnológica está siendo muchísimo mayor que la capacidad de adaptación normativa en muchos países. Y eso plantea preguntas bastante complejas relacionadas con:

- responsabilidad legal,
- uso ético de modelos generativos,
- privacidad
- y límites en el desarrollo de herramientas capaces de replicar identidades digitales.

Finalmente, una posible mejora futura de este propio proyecto sería ampliar considerablemente la investigación primaria. La fase cualitativa incorporada en esta entrega permitió validar ciertas tendencias observadas en la literatura, pero una muestra más amplia y diversa podría aportar resultados mucho más representativos y detallados. Especialmente interesante sería comparar percepción de riesgo entre distintos sectores profesionales o analizar diferencias entre organizaciones con distintos niveles de madurez en ciberseguridad.

En conjunto, todas estas líneas futuras reflejan una idea bastante evidente: el impacto de la IA generativa en ciberseguridad todavía está lejos de estabilizarse. Y probablemente esa sea precisamente una de las mayores dificultades para investigadores, empresas y organismos defensivos durante los próximos años.

17. Reflexión crítica del proyecto

Al finalizar este proyecto, una de las primeras cosas que resulta evidente es que investigar sobre IA generativa y ciberseguridad implica trabajar sobre un escenario extremadamente cambiante. Probablemente esa haya sido la mayor dificultad durante todo el proceso. Muchas de las herramientas, casos y tendencias analizadas evolucionaban incluso mientras se desarrollaba la investigación, lo que obligó a revisar constantemente información y actualizar parte del enfoque inicial.

Al comienzo del proyecto, el objetivo principal era comprender cómo la IA generativa podía utilizarse dentro de ciberataques modernos. Sin embargo, a medida que avanzaba el análisis, quedó claro que el problema era bastante más amplio de lo que parecía inicialmente. Ya no se trata únicamente de automatizar

ataques o generar malware más rápido. El verdadero cambio está relacionado con la capacidad de manipular confianza, identidad y percepción humana utilizando herramientas accesibles y cada vez más convincentes.

Y sinceramente, esa fue probablemente una de las conclusiones más interesantes a nivel personal durante el desarrollo del trabajo. Antes de empezar la investigación, gran parte de la atención mediática alrededor de la IA generativa parecía centrarse casi exclusivamente en productividad o creatividad. Pero al profundizar en informes técnicos y casos reales, empezó a verse con mucha más claridad el impacto que estas tecnologías pueden tener también desde una perspectiva ofensiva.

Otra reflexión importante tiene relación con las limitaciones metodológicas. Aunque el análisis documental permitió construir una base bastante sólida y contrastar información procedente de múltiples fuentes fiables, existe una dependencia inevitable de documentación externa. Muchas empresas no publican detalles completos sobre incidentes reales, especialmente cuando existen implicaciones reputacionales o legales. Eso dificulta validar ciertos casos con total precisión y obliga constantemente a contrastar fuentes antes de extraer conclusiones firmes.

La incorporación de investigación cualitativa ayudó parcialmente a reducir esa dependencia documental. Aunque la muestra utilizada fue pequeña y exploratoria, permitió introducir una dimensión más cercana a la percepción real de usuarios y perfiles técnicos. Y honestamente, esa parte terminó aportando bastante más valor del que parecía al principio. No solo reforzó tendencias observadas en la literatura, sino que también mostró cómo muchas personas empiezan a percibir estas amenazas como algo mucho más cercano y real que hace apenas unos años.

Aun así, también es importante reconocer que esta fase cualitativa presenta limitaciones claras. Los resultados obtenidos no pueden generalizarse y dependen bastante del perfil de participantes seleccionados. Además, debido a restricciones temporales y logísticas, no fue posible desarrollar una investigación primaria más amplia o incorporar entrevistas con profesionales especializados de grandes organizaciones.

Otro aspecto que merece reflexión es el equilibrio entre profundidad técnica y claridad expositiva. Durante el proyecto apareció constantemente la necesidad de simplificar ciertos conceptos para mantener el texto comprensible sin perder rigor académico. Y sinceramente, no siempre resulta fácil. Algunos informes técnicos relacionados con IA ofensiva utilizan terminología muy específica o describen escenarios complejos que pueden resultar difíciles de trasladar a un análisis más general sin perder precisión.

También hubo un desafío importante relacionado con la velocidad de obsolescencia de la información. En áreas tradicionales de investigación, ciertos marcos teóricos pueden mantenerse relativamente estables durante años. Aquí ocurre justo lo contrario. Nuevos modelos, herramientas y riesgos aparecen continuamente, lo que

hace que parte del contenido pueda quedar desactualizado mucho más rápido que en otros ámbitos tecnológicos.

Precisamente por eso, una de las enseñanzas más importantes que deja este proyecto es que la ciberseguridad moderna necesita adaptarse de forma mucho más dinámica. Y no solo desde el punto de vista técnico. La investigación mostró repetidamente que muchas amenazas actuales explotan factores humanos más que vulnerabilidades puramente tecnológicas. Eso obliga a replantear incluso cómo entendemos conceptos como autenticidad, confianza digital o verificación de identidad.

En conjunto, el proyecto permitió no solo analizar una problemática tecnológica emergente, sino también comprender hasta qué punto la IA generativa está modificando la relación entre personas, información y seguridad digital. Y probablemente esa transformación todavía se encuentra en una fase muy inicial.

Bibliografía

- Check Point Research (2024). *Deepfake Cyber Security Threats*. [cite_start]Disponible en: <https://www.checkpoint.com/cyber-hub/threat-prevention/what-is-malware/deepfake-cyber-security-threats/>
- Cisco (2024). *2024 Cisco Cybersecurity Readiness Index*. [cite_start]Disponible en: <https://newsroom.cisco.com/c/r/newsroom/en/us/a/y2024/m03/cybersecurity-readiness-index-2024.html>
- CrowdStrike (2024). *Global Threat Report 2024*. Disponible en: <https://www.crowdstrike.com/global-threat-report/>
- Europol (2024). *Internet Organised Crime Threat Assessment (IOCTA) 2024*. [cite_start]Disponible en: <https://www.europol.europa.eu/publication-events/main-reports/internet-organised-crime-threat-assessment-iocta-2024>
- Google Cloud (2023). *FIDO2 and Passwordless Future*. Disponible en: <https://cloud.google.com/blog/products/identity-security/google-cloud-and-fido2-passwordless>
- IBM Security (2024). *Cost of a Data Breach Report 2024*. [cite_start]Disponible en: <https://www.ibm.com/reports/data-breach>
- Kaspersky (2025). *Ciberamenazas que imitan herramientas de inteligencia artificial aumentan 115% en 2025*. [cite_start]Disponible en: <https://latam.kaspersky.com/about/press-releases/ciberamenazas-que-imitan-herramientas-de-inteligencia-artificial-como-chatgpt-aumentan-115-en-2025-kaspersky>

- Microsoft (2023). *Cyber Signals: Shifting tactics driven by AI*. Disponible en: <https://www.microsoft.com/en-us/security/blog/2023/12/07/cyber-signals-shifting-tactics/>
- Microsoft (2024). *Combating Deepfakes: The C2PA Standard*. Disponible en: <https://blogs.microsoft.com/on-the-issues/2024/02/13/combating-deepfakes-c2pa-check-content-credentials/>
- MIT Technology Review (2023). *The rise of AI-generated cyber threats*. [cite_start]Disponible en: <https://www.technologyreview.com/2023/06/12/1072580/ai-generated-cyber-threats/>
- NIST (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. National Institute of Standards and Technology. [cite_start]Disponible en: <https://www.nist.gov/itl/ai-risk-management-framework>
- SlashNext (2024). *The State of Phishing 2024*. [cite_start]Disponible en: <https://slashnext.com/blog/the-state-of-phishing-2024/>
- Check Point Research (2024). *Deepfake Cyber Security Threats*. Disponible en: <https://www.checkpoint.com/cyber-hub/threat-prevention/what-is-malware/deepfake-cyber-security-threats/>
- CrowdStrike (2024). *Global Threat Report 2024*. Disponible en: <https://www.crowdstrike.com/global-threat-report/>
- Google Cloud (2023). *FIDO2 and Passwordless Future*. Disponible en: <https://cloud.google.com/blog/products/identity-security/google-cloud-and-fido2-passwordless>
- IBM Security (2024). *Cost of a Data Breach Report 2024*. Disponible en: <https://www.ibm.com/reports/data-breach>
- Microsoft Security (2023). *Cyber Signals: Shifting tactics driven by AI*. Disponible en: <https://www.microsoft.com/en-us/security/blog/2023/12/07/cyber-signals-shifting-tactics/>
- Microsoft (2024). *Combating Deepfakes: The C2PA Standard*. Disponible en: <https://blogs.microsoft.com/on-the-issues/2024/02/13/combating-deepfakes-c2pa-check-content-credentials/>
- NIST (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. National Institute of Standards and Technology. Disponible en: <https://www.nist.gov/itl/ai-risk-management-framework>